UTS

PEMBELAJARAN MESIN



NAMA : Tiara Anargya Citra

NIM : 202531092

KELAS : H1

DOSEN : Rizqia Cahyaningtyas, ST., M.Kom

NO.PC : 5

ASISTEN : 1. Muhammad Ichwan Fauzi

2. Benedict Samuel Ardy

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

Contents

DAFTAR ISI i
BAB I 1
PENDAHULUAN 1
1.1 Rumusan Masalah 1
1.2 Tujuan Masalah 2
1.3 Manfaat Masalah 2
BAB II 3
LANDASAN TEORI 3
2.1 Pembelajaran Terawasi dan Tidak Terawasi 3
2.2 Eksplorasi Data dan Praproses 3
2.3 Regresi Linear 4
2.4 Analisis Korelasi 5
2.5 Koefisien Determinasi dan Metrik Regresi 6
2.6 Decision Tree 7
2.7 Overfitting dan Pemangkasan 7
2.8 Metrik Evaluasi Klasifikasi 8
2.9 Dataset Bank Customers 8
2.10 Perangkat Pengerjaan 9
2.11 Keterkaitan Teori dengan Praktikum 9
BAB III 10
HASIL 10
3.1 Gambaran Umum Dataset 10
3.2 Eksplorasi Data (EDA) 11
3.2.1 Impor pustaka dan pemuatan data 11
3.2.2 Statistik deskriptif 13
3.2.3 Pengecekan data hilang, duplikat, dan kelas target 14
3.2.4 Distribusi kelas, usia, dan saldo 16
3.2.5 Deteksi outlier dengan metode IQR 18
3.2.6 Korelasi dan hubungan fitur dengan target 20

3.2.7 Hubungan poutcome dan korelasi balance 23
3.3 Praproses Data 24
3.4 Regresi Linear Sederhana 25
3.5 Regresi Linear Berganda 28
3.6 Decision Tree 34
3.6.1 Model tanpa pembatasan kedalaman 35
3.6.2 Pemilihan max_depth berdasarkan data validasi 36
3.6.3 Pelatihan model akhir dan visualisasi pohon 37
3.6.4 Prediksi dan evaluasi 39
3.7 Pembahasan Hasil 41
BAB IV 43
PENUTUP 43
4.1 Kesimpulan 43
DAFTAR PUSTAKA 45

BAB I
PENDAHULUAN

Perkembangan teknologi informasi membuat machine learning semakin sering dipakai di sektor perbankan. Bank menyimpan data nasabah dalam jumlah besar, mulai dari data demografis, riwayat pinjaman, sampai catatan kampanye pemasaran sebelumnya. Data tersebut dapat dimanfaatkan untuk membantu pengambilan keputusan, misalnya menentukan nasabah mana yang paling mungkin bersedia menempatkan dananya dalam deposito berjangka.

Kampanye pemasaran lewat telepon membutuhkan tenaga kerja dan waktu yang tidak sedikit. Setiap panggilan yang tidak berhasil berarti biaya yang terbuang. Karena itu, ketepatan dalam memilih sasaran menjadi faktor penting. Model klasifikasi dapat membantu bank menyusun prioritas panggilan, sedangkan model regresi dapat membantu memperkirakan nilai tertentu dari nasabah, seperti saldo rekening.

Dataset Bank Customers dipilih untuk praktikum ini karena memuat kedua jenis tugas tersebut dalam satu sumber data. Target balance bersifat numerik sehingga cocok untuk regresi, sedangkan target y bersifat kategorik sehingga cocok untuk klasifikasi. Selain itu, dataset ini memiliki kondisi yang menarik untuk dipelajari, seperti nilai unknown, outlier, dan ketidakseimbangan kelas.

1.1 Rumusan Masalah

Praktikum UTS ini memakai dataset Bank Customers (Dataset 4) yang berisi 45.211 data nasabah dengan 17 kolom. Berdasarkan proses pengerjaan tersebut, rumusan masalah yang diajukan adalah sebagai berikut.

1. Bagaimana kemampuan regresi linear sederhana dan regresi linear berganda dalam memprediksi saldo rekening (balance) nasabah?
2. Seberapa baik algoritma decision tree dalam memprediksi apakah nasabah akan berlangganan deposito berjangka (variabel y)?
3. Berapa nilai max_depth yang paling sesuai berdasarkan akurasi pada data validasi, dan bagaimana pengaruhnya terhadap overfitting?
4. Bagaimana kondisi data, seperti nilai unknown, outlier, dan ketidakseimbangan kelas, memengaruhi proses pemodelan?

Keempat rumusan masalah tersebut saling berkaitan. Rumusan pertama dan kedua membahas kemampuan dua algoritma pada dua jenis target yang berbeda, yaitu target numerik dan target kategorik. Rumusan ketiga membahas cara mengendalikan kompleksitas

decision tree agar model tidak sekadar menghafal data latih. Rumusan keempat menyoroti kondisi data yang pada akhirnya ikut menentukan batas kemampuan setiap model.

1.2 Tujuan Masalah

Praktikum ini bertujuan untuk:

- Memahami struktur dan karakteristik dataset melalui exploratory data analysis (EDA).
- Melakukan pengecekan dan praproses data sebelum pelatihan model, termasuk encoding variabel kategorik.
- Membangun model regresi linear sederhana (age terhadap balance) dan regresi linear berganda (seluruh fitur terhadap balance), lalu mengevaluasinya dengan MSE, RMSE, dan R2.
- Membangun model decision tree untuk klasifikasi variabel y dan menentukan max_depth terbaik melalui data validasi.

Hasil yang diperoleh menunjukkan nilai R2 sebesar 0,0061 untuk regresi linear sederhana dan 0,0357 untuk regresi linear berganda, dengan RMSE masing-masing sebesar 2.878,14 dan 2.834,88. Model decision tree terpilih memakai max_depth 6 dan mencapai akurasi data uji sebesar 0,9009.

Hasil tersebut juga memperlihatkan bahwa akurasi yang tinggi belum tentu menunjukkan model yang baik. Pada data yang tidak seimbang, model yang selalu menjawab no sudah memperoleh akurasi 0,8830. Oleh karena itu, pembacaan hasil pada praktikum ini tidak hanya berhenti pada akurasi, tetapi juga memakai presisi dan recall.

1.3 Manfaat Masalah

Bagi penulis, praktikum ini membantu memahami alur kerja machine learning secara utuh, mulai dari eksplorasi data sampai evaluasi model. Teori yang dipelajari di kelas menjadi lebih konkret ketika harus menulis kode sekaligus menafsirkan hasilnya. Penulis juga belajar bahwa keputusan kecil pada tahap praproses, seperti cara menangani nilai unknown atau outlier, dapat memengaruhi hasil akhir.

Bagi bidang perbankan, hasil model klasifikasi dapat dijadikan gambaran awal untuk menentukan nasabah yang perlu diprioritaskan dalam kampanye pemasaran deposito. Dengan daftar prioritas yang lebih tepat, bank dapat mengurangi panggilan yang tidak berhasil dan memusatkan usaha pada nasabah yang lebih berpeluang. Meski demikian, model ini perlu diuji lebih lanjut sebelum digunakan dalam keputusan nyata.

Di sisi lain, hasil regresi yang sangat rendah menunjukkan bahwa fitur pada dataset ini belum cukup untuk memperkirakan saldo nasabah secara akurat. Manfaat model regresi untuk tugas tersebut menjadi terbatas. Temuan ini dapat menjadi dasar pengembangan berikutnya, misalnya dengan menambah fitur, mengubah bentuk variabel target, atau mencoba model non-linear.

BAB II

LANDASAN TEORI

Bab ini menjelaskan teori yang menjadi dasar praktikum. Setiap teori dikaitkan dengan bagian kode yang dipakai pada Bab III. Sumber yang digunakan berupa jurnal ilmiah yang terbit dalam empat tahun terakhir, ditambah materi perkuliahan.

2.1 Pembelajaran Terawasi dan Tidak Terawasi

Pembelajaran terawasi adalah pendekatan machine learning yang melatih model menggunakan data yang sudah memiliki label. Setelah model terbentuk, model dipakai untuk memprediksi data baru yang labelnya belum diketahui. Decision tree termasuk algoritma yang populer untuk tugas pembelajaran terawasi (Alsulami dkk., 2026).

Pembelajaran tidak terawasi bekerja dengan cara yang berbeda. Algoritma pada kelompok ini menerima data tanpa label dan mencari pola yang tersembunyi di dalamnya. Chaudhry dkk. (2023) menjelaskan bahwa data mining memanfaatkan teknik seperti clustering, association rule mining, klasifikasi, dan deteksi anomali untuk menemukan pola pada data. Pada materi perkuliahan, kelompok ini juga mencakup pengurangan dimensi, yaitu mengurangi jumlah fitur tanpa menghilangkan informasi yang penting.

Pada praktikum ini, pendekatan yang dipakai adalah pembelajaran terawasi. Target balance dan target y sudah tersedia pada setiap baris data, sehingga model dapat dilatih untuk meniru pola yang sudah diketahui. Tugas regresi dipakai untuk target numerik, sedangkan tugas klasifikasi dipakai untuk target kategorik. Perbedaan keduanya terletak pada bentuk keluaran. Regresi menghasilkan nilai kontinu, sedangkan klasifikasi menghasilkan kelas.

2.2 Eksplorasi Data dan Praproses

Eksplorasi data dilakukan sebelum pemodelan untuk memahami bentuk data, sebaran nilai, dan hubungan antar variabel. Tahap ini penting karena kualitas model sangat bergantung pada kualitas data. Antoska-Knights dan Prchkovska (2024) juga memperlihatkan bahwa praproses data dan evaluasi model merupakan bagian yang tidak terpisahkan dari penerapan regresi linear berganda.

Pemeriksaan awal mencakup pencarian nilai hilang, data duplikat, dan nilai yang tidak lazim. Nilai unknown pada kolom kategorik perlu mendapat perhatian khusus. Nilai tersebut dapat diperlakukan sebagai kategori tersendiri agar informasi bahwa data tidak tercatat tetap terbawa ke dalam model. Cara ini dipilih karena jumlahnya besar dan kehilangannya akan membuang banyak baris.

Data dengan kelas yang tidak seimbang menjadi masalah tersendiri. Hasnataeni dkk. (2025) menunjukkan bahwa data yang tidak seimbang menyulitkan model untuk mengenali

kelas minoritas dengan baik. Masalah ini relevan karena kelas berlangganan (yes) pada dataset ini hanya sekitar 11,7 persen dari seluruh data.

Pencilan (outlier) dideteksi dengan metode interquartile range (IQR). Nilai kuartil pertama (Q1) dan kuartil ketiga (Q3) dihitung dari data, lalu batas bawah (Q1 - 1,5 x IQR) dan batas atas (Q3 + 1,5 x IQR) menentukan nilai yang dianggap menyimpang. Nilai di luar batas tersebut tidak otomatis dibuang, karena nilai ekstrem bisa jadi merupakan informasi yang valid. Materi perkuliahan juga menekankan bahwa pencilan perlu dikenali sebelum model dibangun, karena pencilan dapat menarik garis regresi menyimpang dari pola umum data.

Variabel kategorik perlu diubah menjadi angka sebelum dipakai model regresi maupun decision tree. Praktikum ini memakai one-hot encoding melalui fungsi get_dummies, yang membuat satu kolom biner untuk setiap kategori. Pada regresi berganda, satu kategori dibuang per variabel (drop_first=True) agar tidak terjadi ketergantungan sempurna antar kolom biner. Pada decision tree, seluruh kategori dipertahankan karena model tersebut tidak mengalami masalah yang sama.

2.3 Regresi Linear

Regresi linear sederhana memodelkan hubungan antara satu variabel bebas (X) dan satu variabel terikat (Y) dengan persamaan garis Y = a + bX. Nilai a adalah intersep, yaitu nilai Y ketika X bernilai nol, sedangkan b adalah koefisien regresi yang menunjukkan kemiringan garis. Koefisien tersebut diestimasi dengan metode kuadrat terkecil (least squares) (Antoska-Knights & Prchkovska, 2024).

Metode kuadrat terkecil mencari garis yang membuat jumlah kuadrat selisih antara nilai aktual dan nilai hasil garis sekecil mungkin. Selisih tersebut disebut residual, yaitu jarak vertikal antara titik data dan garis regresi. Dengan notasi jumlah dari materi perkuliahan, koefisien dihitung dengan rumus berikut.

$$b = (n \times Sum(xy) - Sum(x) \times Sum(y)) / (n \times Sum(x2) - (Sum(x))2)$$

$$a = (Sum(y) - b \times Sum(x)) / n$$

Materi perkuliahan memberikan contoh penerapan sederhana, yaitu hubungan antara anggaran promosi dan jumlah mahasiswa baru selama beberapa tahun. Contoh seperti ini mudah dipahami dan diinterpretasikan. Regresi linear sederhana karena itu sering dipakai sebagai analisis awal dalam penelitian, seperti yang dilaporkan Rambe dkk. (2025) pada kajian literatur sistematis mereka di bidang pendidikan dasar.

Regresi linear berganda memperluas model tersebut ke beberapa variabel bebas, yaitu Y = b0 + b1X1 + b2X2 + ... + bnXn + e. Model ini digunakan ketika variabel terikat dipengaruhi oleh lebih dari satu faktor, karena kemampuannya menganalisis hubungan linear antara satu variabel terikat dan beberapa variabel bebas sekaligus (Harefa, 2025). Pada praktikum ini, variabel kategorik diubah menjadi kolom biner sehingga dapat ikut dihitung dalam persamaan.

Regresi linear memiliki batas penggunaan yang perlu diperhatikan. Penggunaan garis regresi untuk memprediksi nilai yang berada di dalam rentang data disebut interpolasi, sedangkan penggunaannya untuk nilai di luar rentang data disebut ekstrapolasi. Drăgoi dkk. (2026) membandingkan beberapa metode interpolasi dan ekstrapolasi, dan menekankan bahwa hasil di dalam rentang data umumnya lebih andal dibanding hasil di luar rentang. Pada praktikum ini, prediksi dilakukan pada data uji yang berasal dari distribusi yang sama dengan data latih, sehingga risiko ekstrapolasi relatif kecil.

Asumsi utama regresi linear adalah hubungan antar variabel bersifat linear. Jika hubungan sebenarnya melengkung, garis lurus tidak lagi mewakili pola data dengan baik. Outlier juga dapat menarik garis regresi ke arah tertentu, terutama pada data dengan distribusi yang sangat condong seperti balance pada dataset ini.

2.4 Analisis Korelasi

Korelasi adalah ukuran asosiasi yang menunjukkan kekuatan hubungan antara dua variabel. Ele dan Ideochi (2023) menjelaskan bahwa korelasi digunakan untuk menunjukkan seberapa kuat dua variabel saling berkaitan, dan koefisien Pearson merupakan bentuk yang paling umum dipakai untuk mengukur hubungan linear. Korelasi tidak menunjukkan sebab akibat, sehingga nilai korelasi yang tinggi belum tentu berarti satu variabel memengaruhi variabel lain.

Koefisien korelasi Pearson (r) dihitung dengan rumus berikut. Nilainya berada di antara -1 dan 1. Nilai r sama dengan 1 atau -1 menunjukkan hubungan linear yang sempurna, sedangkan nilai r sama dengan 0 menunjukkan tidak adanya hubungan linear. Tanda positif atau negatif menunjukkan arah hubungan.

r = (n x Sum(xy) - Sum(x) x Sum(y)) / sqrt((n x Sum(x2) - (Sum(x))2) x (n x Sum(y2) - (Sum(y))2))

Pada diagram pencar, arah hubungan dapat dibaca dari tren titik-titik data. Korelasi positif terlihat ketika nilai variabel bebas naik dan nilai variabel terikat ikut naik. Korelasi negatif terlihat ketika nilai variabel terikat turun saat variabel bebas naik. Jika titik-titik tersebar tanpa pola, hubungan antar variabel dapat dikatakan lemah atau tidak ada. Semakin rapat titik-titik mengikuti garis, semakin kuat hubungannya.

Kekuatan hubungan juga dapat dibaca dari kuadrat koefisien korelasi, yaitu koefisien determinasi (r2). Materi perkuliahan membagi tingkat korelasi berdasarkan nilai r2 seperti pada Tabel 2.1. Pembagian ini membantu pembaca menilai apakah suatu model cukup baik dalam menjelaskan data.

Tabel 2.1 Kategori tingkat korelasi berdasarkan nilai r2

Nilai r2	Tingkat korelasi
r2 = 0	Tidak ada korelasi
0 < r2 < 0,25	Sangat lemah
0,25 <= r2 <= 0,50	Lemah
0,50 <= r2 < 0,75	Sedang
0,75 <= r2 < 0,90	Kuat
0,90 <= r2 < 1	Sangat kuat
r2 = 1	Sempurna

2.5 Koefisien Determinasi dan Metrik Regresi

Koefisien determinasi (R2) menunjukkan proporsi variasi variabel terikat yang dapat dijelaskan oleh variabel bebas. Pada regresi linear sederhana, nilainya sama dengan kuadrat dari r. Nilai R2 sebesar 0,0061 dapat dibaca sebagai 0,61 persen, yang berarti bagian kecil dari variasi saldo berhasil dijelaskan oleh usia. Semakin besar nilainya, semakin besar bagian variasi data yang dapat dijelaskan model.

Selain R2, kualitas regresi diukur dengan galat rata-rata. MSE adalah rata-rata kuadrat residual, sedangkan RMSE adalah akar dari MSE sehingga satuannya sama dengan satuan variabel target. Syakrani dan Athaya (2025) memakai RMSE untuk menilai model regresi multivariabel pada prediksi temperatur. Dalam penelitian tersebut, nilai R2 pada salah satu sampel model bahkan bernilai negatif, sehingga R2 perlu dibaca bersama metrik error lain dan tidak boleh dipakai sendirian.

MSE memberikan bobot besar pada selisih yang besar karena selisih tersebut dikuadratkan. Akibatnya, beberapa prediksi yang meleset jauh dapat mendominasi nilai MSE. RMSE lebih mudah diinterpretasikan karena berada pada satuan yang sama dengan balance. Dengan membandingkan RMSE terhadap simpangan baku target, pembaca dapat menilai apakah model memberi perbaikan dibanding menebak nilai rata-rata.

2.6 Decision Tree

Decision tree adalah model yang menyusun aturan keputusan dalam bentuk pohon. Simpul internal menguji satu atribut, setiap cabang mewakili hasil pengujian tersebut, dan setiap daun berisi kelas prediksi. Konsep ini membuat decision tree dapat diubah menjadi

aturan keputusan yang mudah dibaca (Surahmat & Sutrisno, 2023). Simpul paling atas disebut akar, yaitu atribut yang paling menentukan pemisahan data.

Pemilihan atribut untuk setiap simpul dilakukan dengan mengukur ketidakpastian data. Entropy mengukur tingkat keberagaman kelas pada suatu simpul dan bernilai nol jika seluruh data pada simpul tersebut berasal dari satu kelas (Halimatussa'diyah & Rohman, 2026). Rumus entropy untuk data dengan dua kelas adalah sebagai berikut.

$$Entropy(S) = -(p1 \times log2(p1) + p2 \times log2(p2))$$

Information gain adalah selisih antara entropy sebelum dan sesudah data dipisah oleh suatu atribut (Pradana dkk., 2024). Atribut dengan information gain terbesar dipilih sebagai simpul dan pada akhirnya menjadi akar pohon (Surahmat & Sutrisno, 2023). Materi perkuliahan memberikan contoh dengan entropy awal sebesar 0,940. Dari contoh tersebut, information gain atribut age sebesar 0,246, atribut student sebesar 0,152, atribut credit rating sebesar 0,048, dan atribut income sebesar 0,029. Nilai terbesar berada pada age, sehingga atribut tersebut dipilih sebagai akar.

$$Gain(S, A) = Entropy(S) - sum(|Sv| / |S| \times Entropy(Sv))$$

Proses pemilihan atribut diulang pada setiap cabang sampai seluruh simpul murni atau tidak ada lagi atribut yang dapat dipakai untuk memisahkan data. Selain entropy, impurity dapat diukur dengan indeks Gini. Alsulami dkk. (2026) membahas entropy Shannon dan indeks Gini sebagai ukuran impurity klasik yang banyak dipakai dalam pembentukan pohon keputusan. Parameter criterion="entropy" pada scikit-learn menghitung information gain, bukan gain ratio seperti pada algoritma C4.5.

2.7 Overfitting dan Pemangkasan

Kelemahan utama decision tree adalah overfitting. Pohon yang tumbuh terlalu dalam akan menghafal data latih sehingga akurasinya pada data baru menurun. Halabaku dan Bytyçi (2024) membahas overfitting pada decision tree dan menjelaskan bahwa penyeimbangan kompleksitas model dapat menjaga akurasi sambil mengurangi overfitting.

Pemangkasan (pruning) adalah cara untuk mengatasi overfitting. Pada pre-pruning, pembentukan pohon dihentikan lebih awal, misalnya dengan membatasi kedalaman pohon. Pada post-pruning, pohon dibentuk sampai selesai terlebih dahulu, kemudian cabang yang tidak memberi kontribusi berarti dibuang. Halabaku dan Bytyçi (2024) menjelaskan bahwa pemangkasan dan pemilihan parameter melalui validasi silang menjadi cara untuk menjaga keseimbangan antara akurasi dan kompleksitas.

Pada praktikum ini, pembatasan kedalaman melalui parameter max_depth berfungsi sebagai bentuk pre-pruning sederhana. Nilai max_depth dipilih dari beberapa kandidat berdasarkan akurasi pada data validasi, bukan data uji, sehingga data uji tetap dapat dipakai untuk evaluasi akhir. Sebagai pembanding, Hayder dkk. (2023) melaporkan bahwa decision tree menjadi model terbaik dengan akurasi 91 persen dibanding k-NN, naive Bayes, dan SVM pada data bank marketing.

Decision tree memiliki kelebihan dan kekurangan yang perlu dipahami sebelum digunakan. Kelebihannya adalah mudah diimplementasikan, hasilnya mudah dipahami, dan proses pembentukannya relatif efisien. Kekurangannya adalah rentan terhadap overfitting, akurasi pada data baru bisa rendah, dan pohon dapat menjadi sangat kompleks pada data yang rumit. Untuk mengatasi kekurangan tersebut, pengembangan seperti random forest dipakai karena membantu mengurangi overfitting dibanding decision tree tunggal (Halabaku & Bytyçi, 2024).

2.8 Metrik Evaluasi Klasifikasi

Akurasi adalah proporsi prediksi yang benar terhadap seluruh data uji. Pada data yang tidak seimbang, akurasi dapat terlihat tinggi walaupun model gagal mengenali kelas minoritas. Hasnataeni dkk. (2025) menilai model pada data bank marketing yang tidak seimbang dengan akurasi, presisi, recall, F1-score, dan AUC sekaligus.

Confusion matrix memuat jumlah true positive (TP), true negative (TN), false positive (FP), dan false negative (FN). Dari nilai tersebut dihitung presisi sebagai TP / (TP + FP), recall sebagai TP / (TP + FN), dan F1-score sebagai rata-rata harmonik dari presisi dan recall. Abidin dkk. (2025) juga menggunakan confusion matrix dan kurva precision-recall untuk menilai model pada data pemasaran deposito.

Abidin dkk. (2025) menyebut bahwa ketidakseimbangan kelas sering muncul pada data pemasaran, dan teknik seperti SMOTE dipakai untuk membangkitkan contoh sintetis pada kelas minoritas. Dengan demikian, pada data seperti ini, recall kelas minoritas perlu diperhatikan sama pentingnya dengan akurasi keseluruhan.

2.9 Dataset Bank Customers

Dataset yang dipakai berasal dari kampanye telemarketing sebuah bank di Portugal. Abidin dkk. (2025) memakai dataset bank marketing dengan 45.211 catatan dari kampanye tersebut, dan dataset ini juga digunakan dalam penelitian lain tentang prediksi berlangganan deposito (Hayder dkk., 2023).

Setiap baris merepresentasikan satu nasabah yang dihubungi. Target y menunjukkan apakah nasabah berlangganan deposito berjangka (yes) atau tidak (no). Karena kelas yes hanya sekitar 11,7 persen dari seluruh data, dataset ini tergolong tidak seimbang. Kondisi ini perlu diingat ketika membaca hasil evaluasi pada Bab III.

2.10 Perangkat Pengerjaan

Praktikum ini dikerjakan dengan bahasa Python di dalam notebook. Pustaka pandas dipakai untuk membaca dan mengolah tabel, NumPy untuk operasi numerik, dan matplotlib bersama seaborn untuk membuat grafik. Pembagian data, regresi linear, dan decision tree dikerjakan dengan scikit-learn. Notebook memisahkan setiap tahap ke dalam sel tersendiri, sehingga hasil setiap langkah dapat diperiksa sebelum lanjut ke langkah berikutnya.

Pemisahan data latih dan data uji dilakukan dengan fungsi train_test_split. Parameter random_state=0 dipakai agar pembagian data selalu sama setiap kali kode dijalankan, sehingga hasil dapat direproduksi. Untuk decision tree, data latih dibagi lagi menjadi data latih dan data validasi, sehingga data uji hanya dipakai pada tahap evaluasi akhir.

Alur pembentukan decision tree pada praktikum ini dimulai dari pemilihan atribut akar berdasarkan information gain, pembentukan cabang secara rekursif, dan penghentian pembentukan ketika kedalaman mencapai max_depth atau simpul sudah murni. Setelah pohon terbentuk, prediksi dilakukan dengan menelusuri cabang dari akar sampai daun. Alur ini sejalan dengan penjelasan pada subbab 2.6 dan 2.7.

2.11 Keterkaitan Teori dengan Praktikum

Teori pada subbab sebelumnya tidak berdiri sendiri, melainkan menjadi dasar keputusan yang diambil selama praktikum. Pemilihan regresi linear untuk target balance didasarkan pada sifat target yang numerik. Pemilihan decision tree untuk target y didasarkan pada sifat target yang kategorik serta kemudahan membaca aturan keputusan dari pohon yang terbentuk.

Teori tentang korelasi dan koefisien determinasi dipakai untuk menafsirkan hasil regresi. Nilai R2 sebesar 0,0061 dan 0,0357 berada pada kategori yang sangat rendah menurut pembagian pada Tabel 2.1. Hal ini menjadi dasar kesimpulan bahwa fitur pada dataset ini tidak cukup kuat menjelaskan saldo nasabah secara linear.

Teori tentang overfitting dan pemangkasan dipakai untuk memilih max_depth. Perbandingan akurasi latih dan akurasi validasi menjadi alat utama untuk melihat kapan pohon mulai menghafal data. Teori metrik evaluasi klasifikasi kemudian dipakai untuk membaca hasil akhir secara lebih lengkap daripada hanya melihat akurasi.

BAB III
HASIL

3.1 Gambaran Umum Dataset

Dataset dimuat dengan pemisah kolom berupa tanda baca titik koma dan menghasilkan 45.211 baris serta 17 kolom. Tidak ada kolom yang kosong. Tabel 3.1 merangkum fungsi setiap kolom.

Tabel 3.1 Deskripsi kolom dataset Bank Customers

Kolom	Tipe	Keterangan
age	Numerik	Usia nasabah dalam tahun
job	Kategorik	Jenis pekerjaan, 12 kategori
marital	Kategorik	Status pernikahan, 3 kategori
education	Kategorik	Jenjang pendidikan, 4 kategori
default	Kategorik	Nasabah tercatat memiliki kredit macet (yes/no)
balance	Numerik	Saldo rekening, dapat bernilai negatif
housing	Kategorik	Nasabah memiliki pinjaman rumah (yes/no)
loan	Kategorik	Nasabah memiliki pinjaman pribadi (yes/no)
contact	Kategorik	Jenis kontak, 3 kategori, termasuk unknown
day	Numerik	Tanggal terakhir nasabah dihubungi
month	Kategorik	Bulan terakhir nasabah dihubungi
duration	Numerik	Durasi panggilan terakhir dalam detik
campaign	Numerik	Jumlah kontak selama kampanye ini
pdays	Numerik	Hari sejak kontak terakhir pada kampanye sebelumnya, -1 jika belum pernah

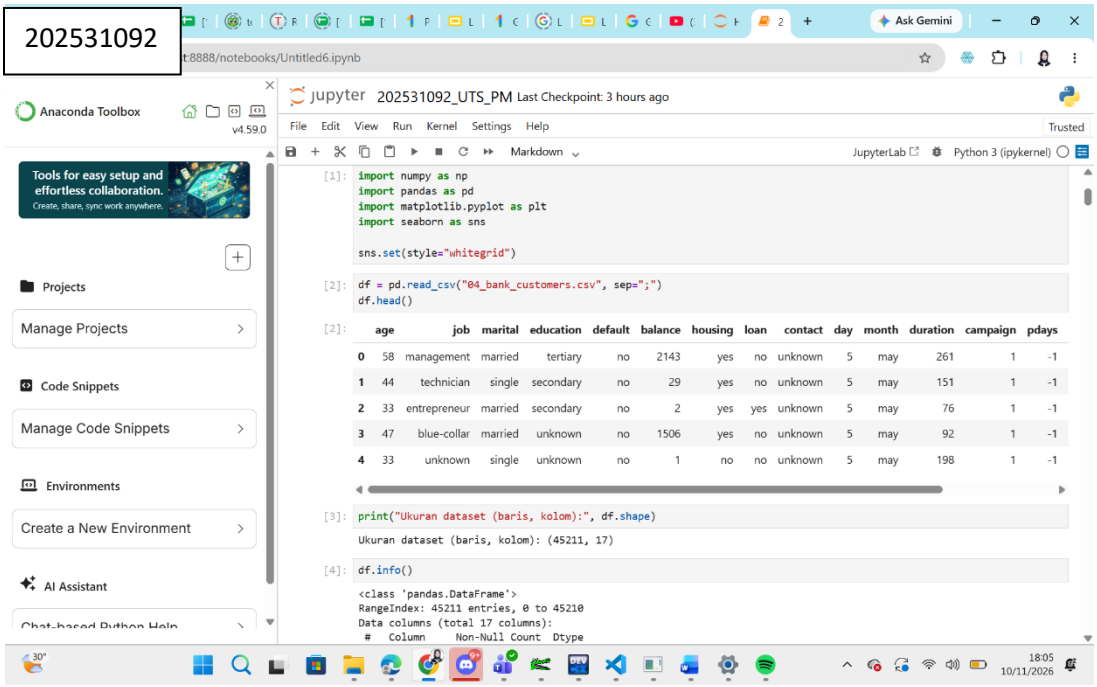
Kolom	Tipe	Keterangan
previous	Numerik	Jumlah kontak sebelum kampanye ini
poutcome	Kategorik	Hasil kampanye sebelumnya, 4 kategori termasuk unknown
y	Kategorik	Target, apakah nasabah berlangganan deposito (yes/no)

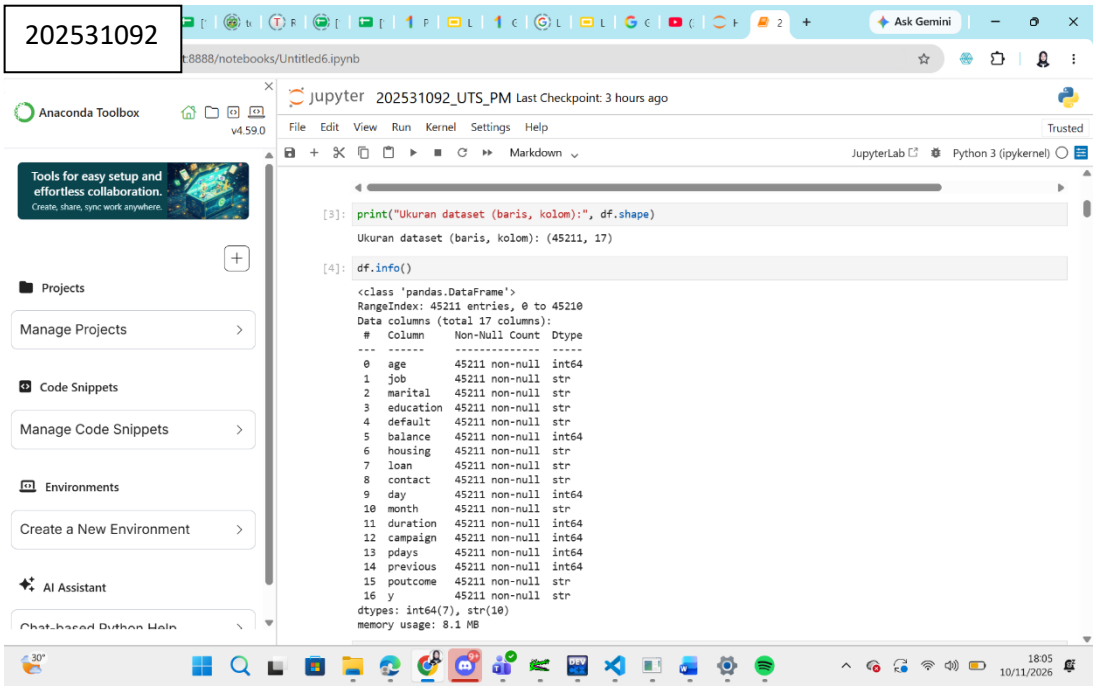
Bagian ini penting karena seluruh keputusan pada tahap pemodelan bergantung pada pemahaman terhadap data. Setiap kolom pada dataset merepresentasikan satu aspek dari nasabah. Kolom age dan balance berisi nilai numerik, sehingga dapat dihitung rata-rata, median, dan sebarannya. Kolom job, marital, education, dan poutcome berisi kategori, sehingga perlu dihitung frekuensinya dan diubah menjadi angka sebelum dipakai model. Kolom pdays menggunakan nilai -1 sebagai penanda khusus, sehingga pembacaannya harus dilakukan dengan hati-hati agar tidak dianggap sebagai nilai hari yang sebenarnya.

Dataset ini juga memiliki karakteristik yang membedakannya dari data latihan yang biasa. Kolom contact, poutcome, dan education memiliki kategori unknown, yang menandakan bahwa informasi tersebut tidak tercatat. Kategori ini tidak boleh dianggap sama dengan data kosong karena jumlahnya cukup besar dan mungkin memiliki pola tersendiri. Karena itu, penjelasan pada bagian EDA dan praproses dibuat terpisah agar pembaca dapat mengikuti alasan setiap keputusan.

3.2 Eksplorasi Data (EDA)

3.2.1 Impor pustaka dan pemuatan data





Gambar 3.1 Impor pustaka dan pemuatan dataset

Gambar 3.1 memuat pustaka yang dibutuhkan. NumPy dipakai untuk operasi numerik, pandas untuk membaca dan mengolah tabel, serta matplotlib dan seaborn untuk visualisasi. Baris sns.set(style="whitegrid") mengatur tampilan grafik agar latarnya putih dengan garis kisi.

Fungsi pd.read_csv membaca file dataset. Karena kolom pada file dipisahkan oleh tanda baca titik koma, parameter pemisah pada fungsi tersebut wajib diisi sesuai karakter itu. Tanpa parameter ini seluruh baris akan terbaca sebagai satu kolom. Perintah df.head() menampilkan lima baris pertama sebagai pemeriksaan awal.

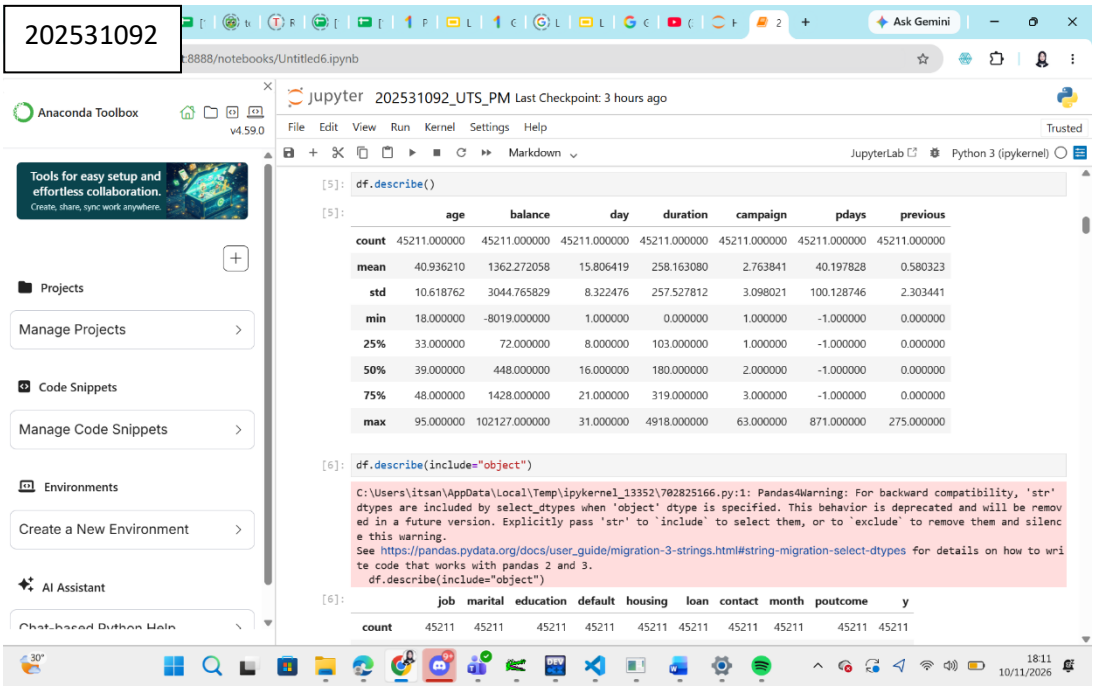
Perintah df.shape menghasilkan (45211, 17), yang berarti dataset memiliki 45.211 baris dan 17 kolom. Perintah df.info() memperlihatkan bahwa seluruh kolom terisi penuh, dengan 7 kolom bertipe int64 dan 10 kolom bertipe str.

Impor pustaka dilakukan di awal notebook agar seluruh sel berikutnya dapat memakai fungsi yang sama. Pandas berperan sebagai alat utama untuk membaca dan memanipulasi tabel, sedangkan NumPy menyediakan operasi matematika pada array. Matplotlib adalah pustaka dasar untuk menggambar grafik, dan seaborn dipakai di atasnya untuk membuat grafik statistik yang lebih rapi dengan sintaks yang lebih singkat. Fungsi sns.set(style="whitegrid") mengubah tampilan seluruh grafik yang dibuat setelahnya menjadi latar putih dengan garis kisi, sehingga nilai pada sumbu lebih mudah dibaca.

Pada sel pemuatan data, fungsi read_csv membaca file dengan parameter sep yang diisi karakter pemisah kolom. Parameter ini wajib diisi karena file dataset menggunakan titik koma sebagai pemisah kolom. Jika parameter ini dihilangkan, pandas akan membaca setiap

baris sebagai satu kolom panjang yang tidak dapat diolah. Perintah df.head() menampilkan lima baris pertama dan membantu memastikan bahwa setiap nilai sudah berada pada kolomnya masing-masing. Pemeriksaan ini sebaiknya selalu dilakukan sebelum melangkah ke tahap berikutnya, karena kesalahan pemuatan data sering tidak langsung terlihat dari pesan kesalahan.

3.2.2 Statistik deskriptif



Gambar 3.2 Statistik deskriptif data

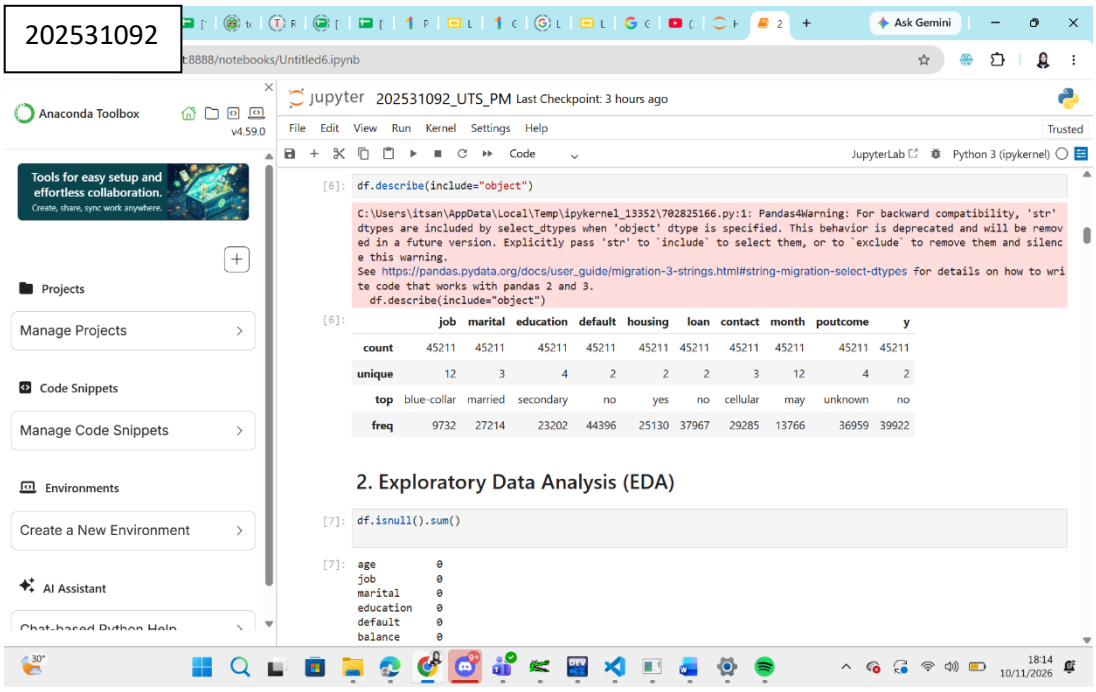
Gambar 3.2 menampilkan ringkasan statistik kolom numerik. Rata-rata usia nasabah adalah 40,94 tahun dengan simpangan baku 10,62. Median saldo hanya 448, jauh di bawah rata-ratanya yang mencapai 1.362,27, sedangkan nilai maksimumnya 102.127. Kondisi ini menunjukkan bahwa distribusi saldo sangat condong ke kanan, sehingga sebagian kecil nasabah memiliki saldo yang sangat besar. Nilai minimum -8.019 menunjukkan adanya rekening dengan saldo negatif.

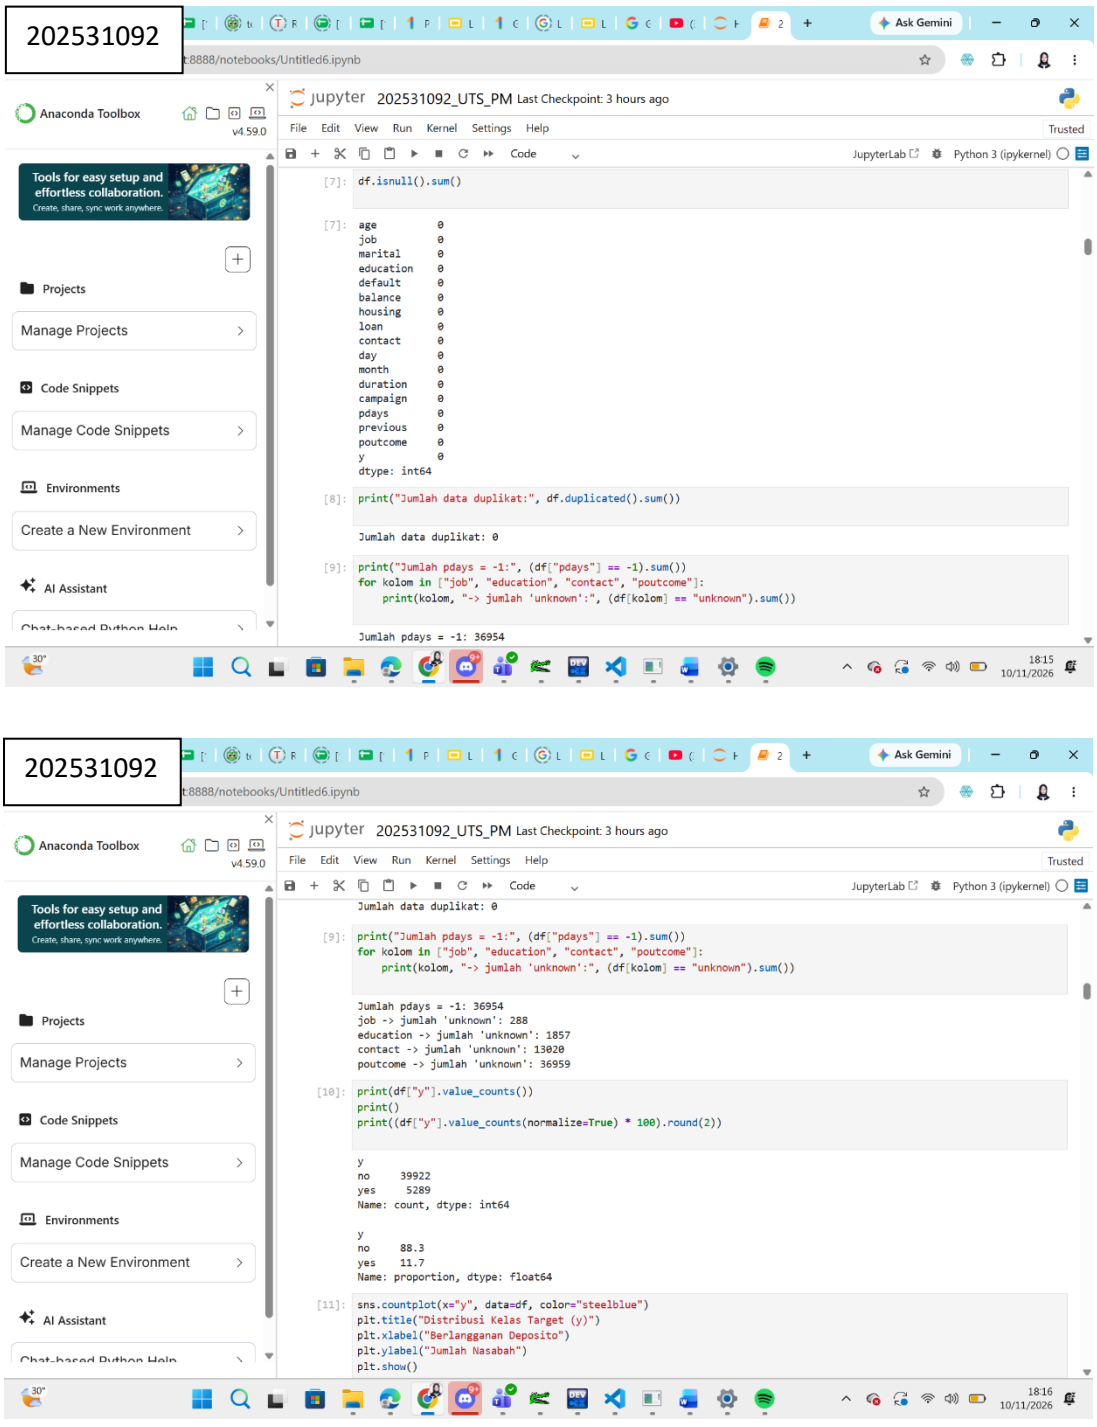
Perintah df.describe(include="object") merangkum kolom kategorik. Pada kolom default, 44.396 dari 45.211 nasabah (98,2 persen) berstatus no. Kategori job yang paling sering muncul adalah blue-collar dengan 9.732 nasabah, dan kategori contact yang paling sering muncul adalah cellular dengan 29.285 nasabah. Output juga memunculkan peringatan Pandas4Warning tentang tipe data str. Peringatan ini tidak memengaruhi hasil dan hanya berkaitan dengan perubahan versi pandas.

Tabel 3.2 Statistik deskriptif kolom numerik

Variabel	Rata-rata	Median	Simpangan baku	Minimum	Maksimum
age	40,94	39	10,62	18	95
balance	1.362,27	448	3.044,77	-8.019	102.127
duration	258,16	180	257,53	0	4.918
campaign	2,76	2	3,10	1	63

3.2.3 Pengecekan data hilang, duplikat, dan kelas target





Gambar 3.3 Pengecekan data hilang, duplikat, dan kelas target

Gambar 3.3 memeriksa kualitas data. Hasilnya menunjukkan tidak ada nilai hilang dan tidak ada data duplikat. Namun, beberapa kategori memakai kode unknown sebagai penanda nilai yang tidak diketahui. Jumlahnya cukup besar pada kolom poutcome (36.959 data atau 81,7 persen) dan contact (13.020 data atau 28,8 persen).

Kolom pdays memakai nilai -1 sebagai penanda bahwa nasabah belum pernah dihubungi pada kampanye sebelumnya. Kondisi ini dialami 36.954 nasabah atau 81,7 persen. Bagian

akhir kode menghitung distribusi kelas target. Sebanyak 39.922 nasabah (88,3 persen) berstatus no dan 5.289 nasabah (11,7 persen) berstatus yes.

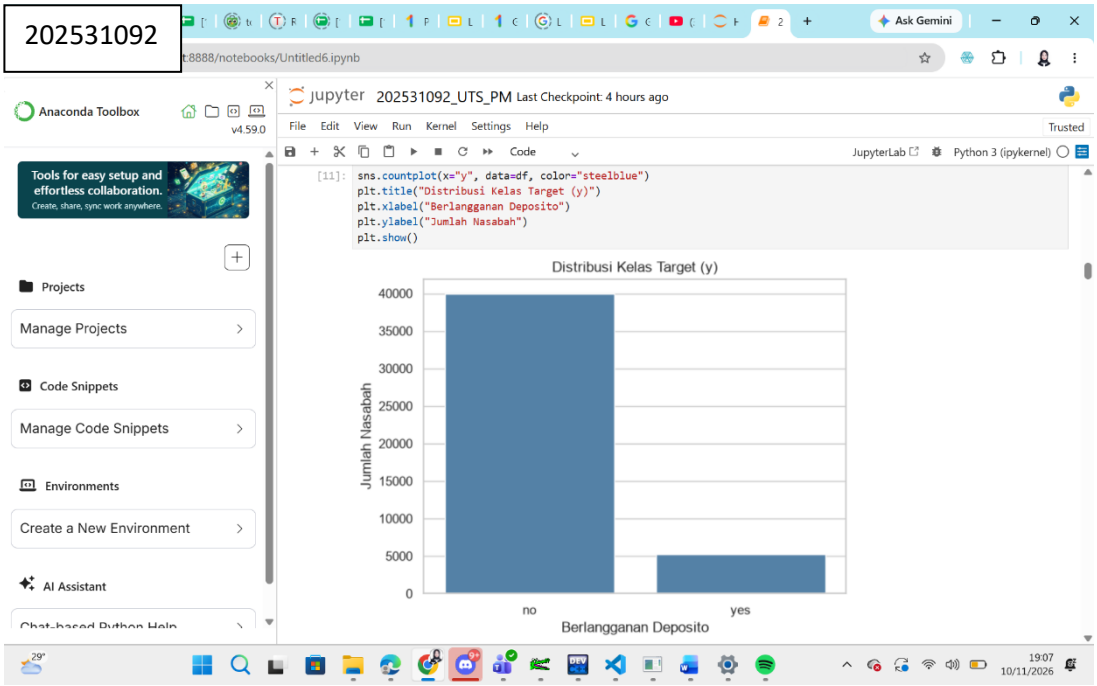
Pemeriksaan data hilang menghasilkan nol pada seluruh kolom, sehingga tidak diperlukan pengisian nilai hilang. Pemeriksaan data duplikat juga menghasilkan nol, sehingga setiap baris merepresentasikan satu nasabah yang berbeda. Dengan demikian, setiap baris merepresentasikan satu nasabah yang berbeda.

Kategori unknown tetap perlu dihitung secara terpisah. Pada kolom poutcome terdapat 36.959 data unknown atau 81,7 persen dari seluruh data. Angka yang besar ini wajar karena poutcome hanya terisi jika nasabah pernah dihubungi pada kampanye sebelumnya. Pada kolom contact terdapat 13.020 data unknown atau 28,8 persen. Keduanya tidak dapat diisi dengan nilai rata-rata atau modus tanpa menambahkan informasi yang belum ada, sehingga dipertahankan sebagai kategori tersendiri.

Kolom pdays memakai nilai -1 untuk menandai nasabah yang belum pernah dihubungi pada kampanye sebelumnya. Sebanyak 36.954 nasabah atau 81,7 persen berada pada kondisi ini. Nilai -1 tidak boleh dibaca sebagai jarak waktu, sehingga pada tahap praproses nilai ini tetap dipertahankan sebagai penanda. Bagian akhir kode menghitung distribusi kelas target dengan value_counts. Sebanyak 39.922 nasabah atau 88,3 persen berstatus no, sedangkan 5.289 nasabah atau 11,7 persen berstatus yes.

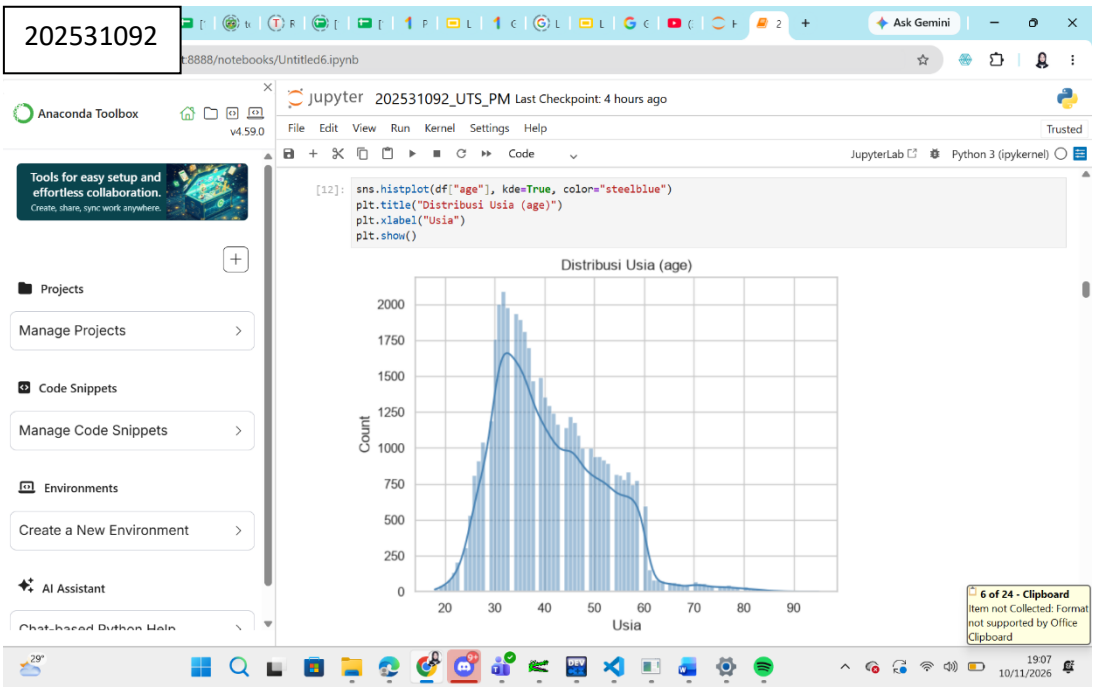
Distribusi kelas ini sangat penting untuk tahap pemodelan. Dataset dengan proporsi yang timpang membuat model dapat memperoleh akurasi tinggi hanya dengan selalu memprediksi kelas mayoritas. Karena itu, angka 88,3 persen perlu dipakai sebagai acuan baseline ketika menilai akurasi model klasifikasi pada Bab 3.6.

3.2.4 Distribusi kelas, usia, dan saldo



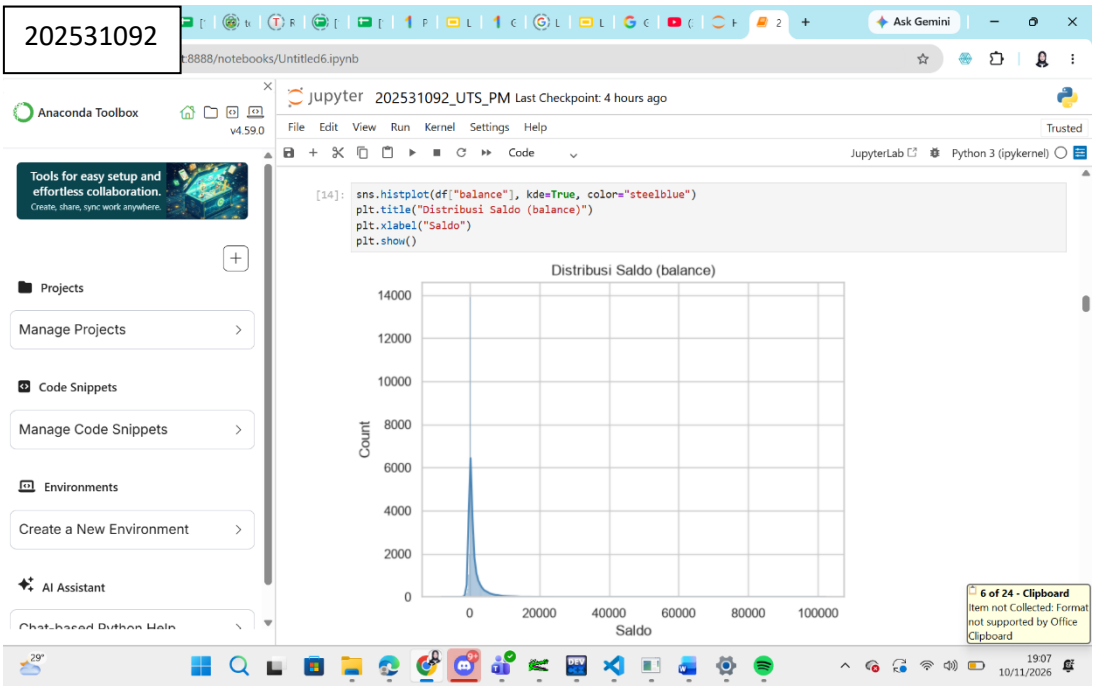
Gambar 3.4 Distribusi kelas target (y)

Gambar 3.4 memperlihatkan ketidakseimbangan kelas dengan jelas. Karena kelas yes sangat sedikit, model yang selalu menjawab no sudah mencapai akurasi 88,3 persen. Akurasi tinggi saja tidak menunjukkan bahwa model mampu mengenali nasabah yang berlangganan.

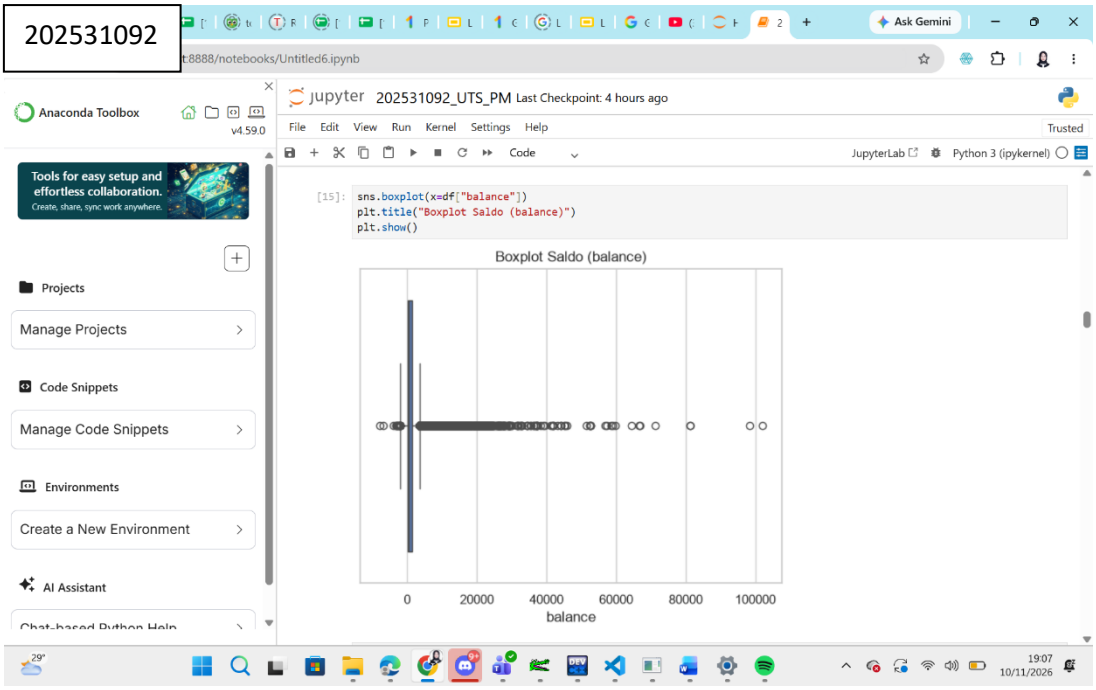


Gambar 3.5 Distribusi usia (age)

Gambar 3.5 menunjukkan bahwa separuh nasabah berusia antara 33 dan 48 tahun. Distribusi usia tidak terlalu condong dibanding saldo.



Gambar 3.6 Distribusi saldo (balance)



Gambar 3.7 Boxplot saldo (balance)

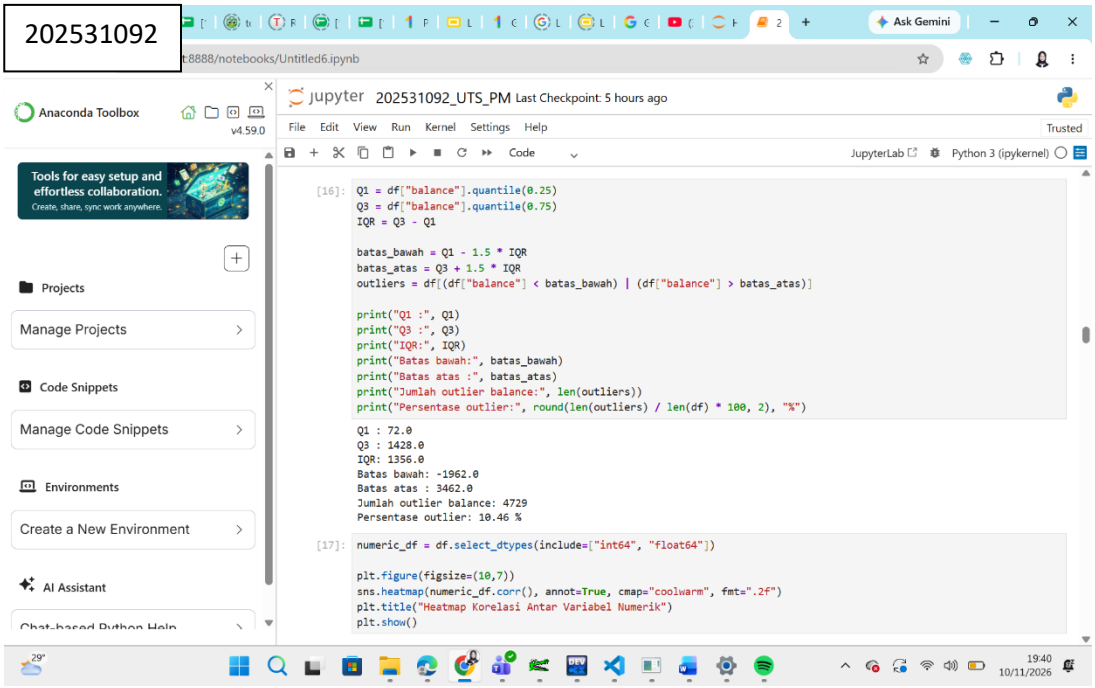
Gambar 3.6 dan Gambar 3.7 memperkuat temuan pada statistik deskriptif. Sebagian besar nasabah memiliki saldo kecil, dengan ekor distribusi yang panjang ke kanan. Banyak titik di luar kotak pada boxplot menandakan adanya nilai ekstrem.

Kode pada sel ini membuat tiga gambar sekaligus, yaitu histogram distribusi kelas, histogram usia, dan histogram saldo. Histogram memperlihatkan bentuk sebaran data dengan membagi nilai ke dalam beberapa interval. Pada histogram usia, sebaran nilai terlihat cukup merata di sekitar median usia. Pada histogram saldo, sebagian besar batang berada di dekat nol, sedangkan ekornya memanjang ke kanan.

Boxplot saldo memperlihatkan lima ringkasan statistik, yaitu nilai minimum, kuartil pertama, median, kuartil ketiga, dan nilai maksimum. Titik-titik di luar whisker menandakan nilai yang dianggap pencilan. Banyaknya titik di sisi atas kotak memperkuat temuan bahwa distribusi saldo condong ke kanan. Ini menunjukkan bahwa penggunaan rata-rata sebagai ukuran pusat data saldo kurang tepat, sehingga median lebih sering dipakai sebagai acuan.

3.2.5 Deteksi outlier dengan metode IQR

202531092



Gambar 3.8 Perhitungan outlier balance dengan metode IQR

Gambar 3.8 menghitung batas outlier untuk kolom balance. Nilai Q1 adalah 72, Q3 adalah 1.428, dan IQR adalah 1.356. Dengan demikian, batas bawah bernilai -1.962 dan batas atas bernilai 3.462. Sebanyak 4.729 data (10,46 persen) berada di luar rentang tersebut.

Nilai outlier pada praproses tidak dihapus. Saldo besar merupakan kondisi nyata pada nasabah bank, sehingga penghapusan berpotensi menghilangkan informasi penting. Dampak outlier terhadap model regresi dibahas pada Bab 3.7.

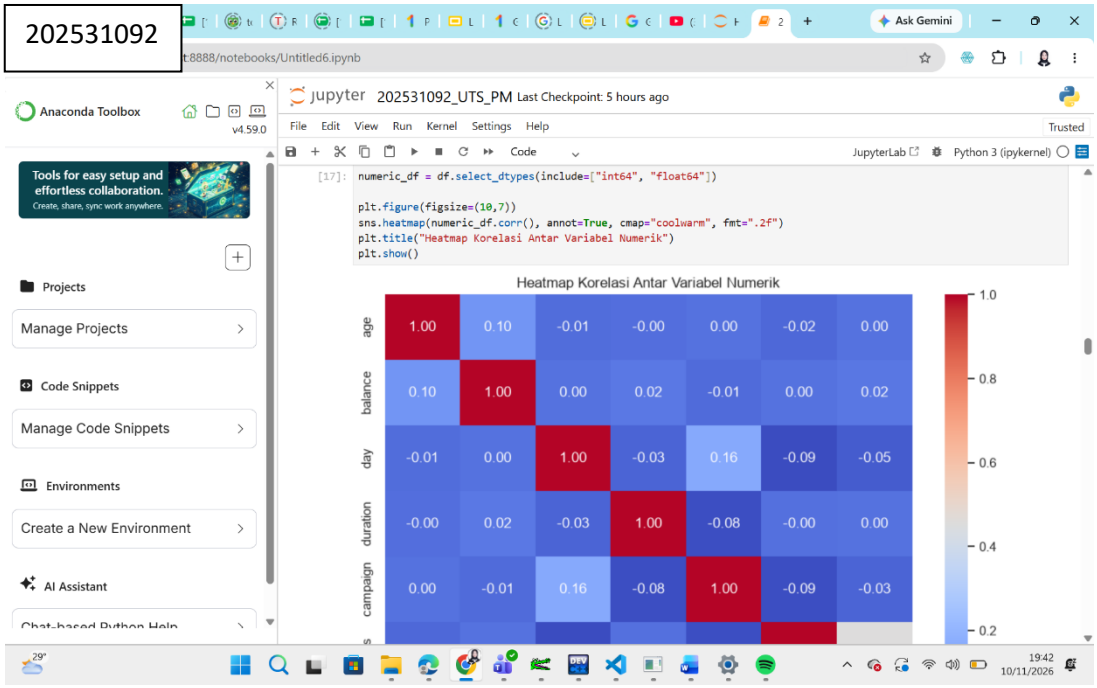
Metode IQR dipilih karena tidak bergantung pada asumsi distribusi normal. Langkah pertama adalah menghitung kuartil pertama dan kuartil ketiga dari kolom balance. Selisih keduanya disebut IQR. Batas bawah dihitung dengan mengurangi 1,5 kali IQR dari Q1, sedangkan batas atas dihitung dengan menambahkan 1,5 kali IQR pada Q3. Nilai di luar kedua batas tersebut ditandai sebagai outlier.

Hasil perhitungan menunjukkan Q1 sebesar 72 dan Q3 sebesar 1.428, sehingga IQR bernilai 1.356. Batas bawah bernilai -1.962 dan batas atas bernilai 3.462. Karena saldo negatif hingga -1.962 masih mungkin terjadi pada rekening nyata, batas bawah tidak dianggap sebagai ukuran yang kaku. Sebanyak 4.729 data atau 10,46 persen berada di luar rentang tersebut.

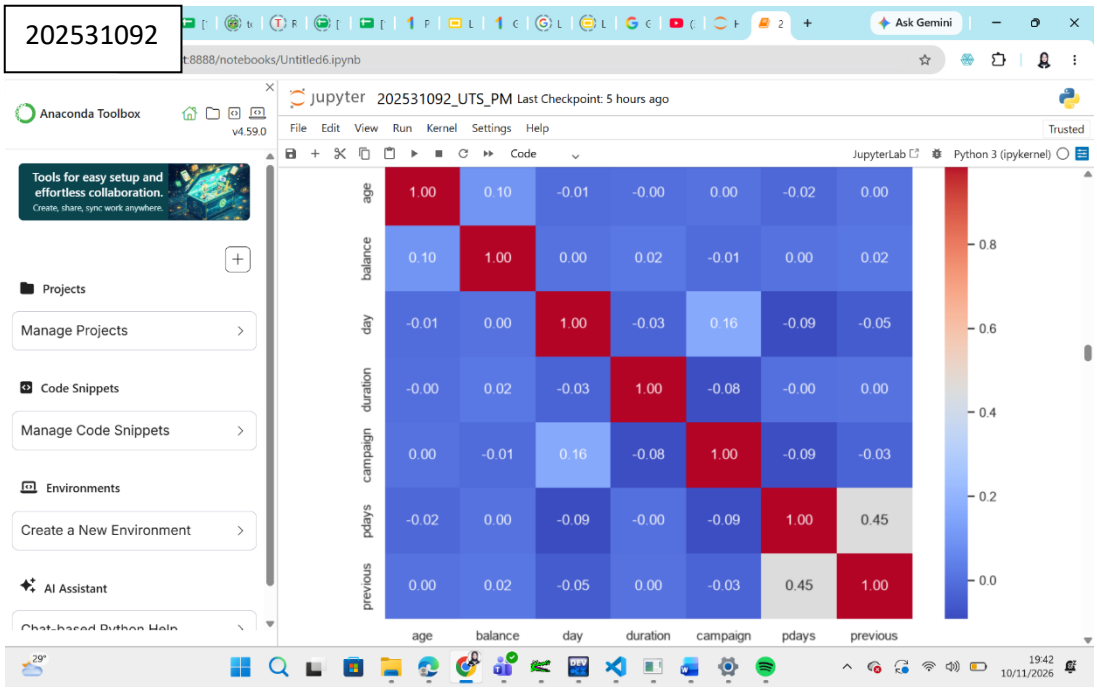
Keputusan untuk tidak menghapus outlier diambil dengan beberapa alasan. Pertama, saldo besar adalah kondisi nyata pada nasabah bank dan bukan kesalahan pencatatan. Kedua, jumlah outlier cukup besar sehingga penghapusannya akan mengurangi data secara signifikan. Ketiga, dampak outlier dapat diamati langsung dari hasil regresi pada Bab 3.4 dan 3.5, sehingga keputusan ini tetap dapat dievaluasi.

3.2.6 Korelasi dan hubungan fitur dengan target

202531092

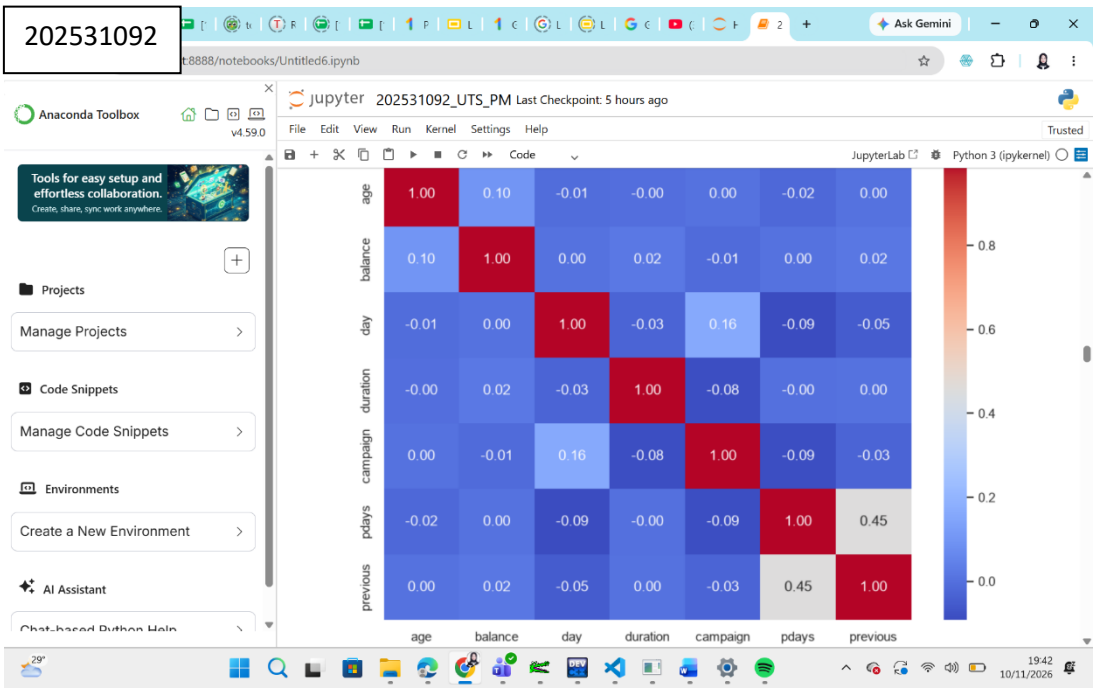


202531092

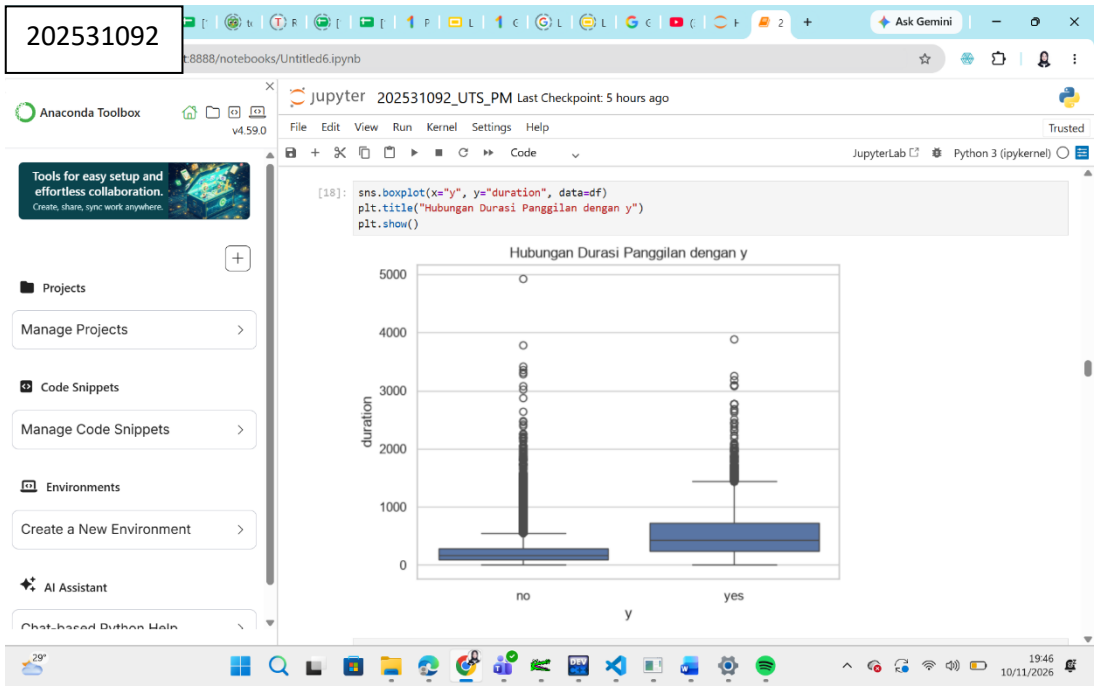


Gambar 3.9 Kode korelasi dan hubungan fitur dengan y

Gambar 3.9 menghitung matriks korelasi Pearson untuk kolom numerik, lalu membuat heatmap dan dua boxplot. Heatmap pada Gambar 3.10 memakai warna untuk menunjukkan kekuatan korelasi antar pasangan variabel numerik.

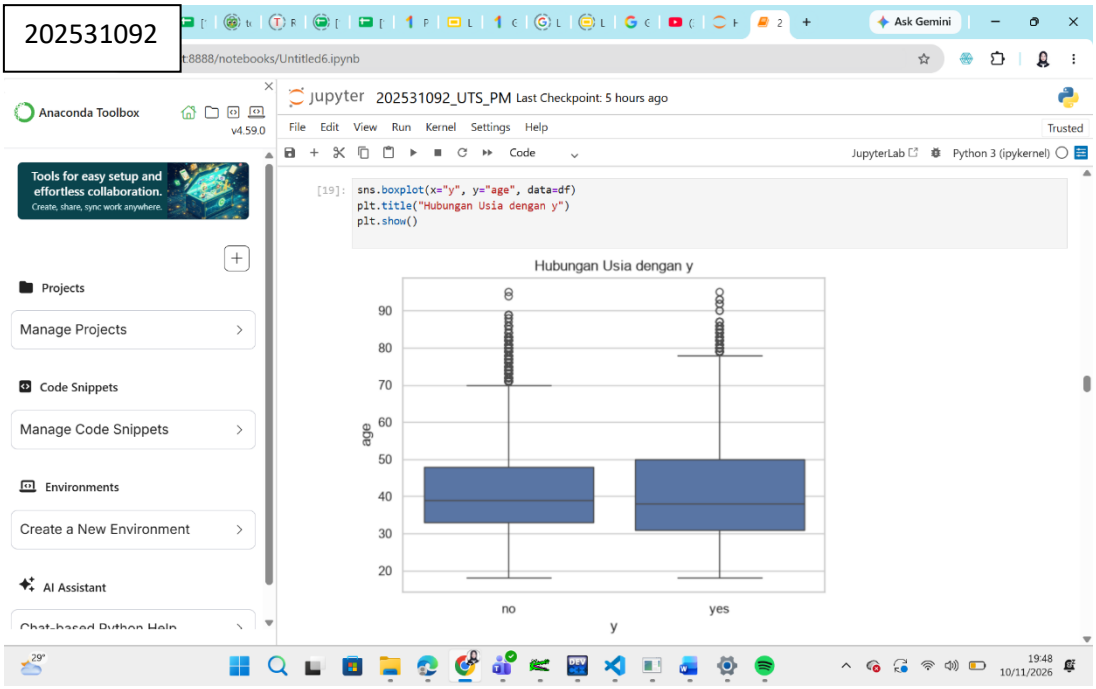


Gambar 3.10 Heatmap korelasi antar variabel numerik



Gambar 3.11 Boxplot durasi panggilan terhadap y

Gambar 3.11 menunjukkan bahwa median durasi panggilan pada kelas yes lebih tinggi dibanding kelas no. Kelas yes juga memiliki kotak yang lebih lebar. Pola ini menunjukkan bahwa durasi panggilan berkaitan dengan keputusan nasabah. Namun, durasi baru diketahui setelah panggilan selesai. Hal ini menjadi catatan penting pada pembahasan.



Gambar 3.12 Boxplot usia terhadap y

Gambar 3.12 memperlihatkan median usia kedua kelas yang hampir sama, yaitu sekitar 38 sampai 39 tahun. Usia saja belum cukup untuk memisahkan kedua kelas dengan jelas.

Kode korelasi menghitung matriks korelasi Pearson hanya untuk kolom numerik, karena korelasi Pearson memerlukan data yang bersifat numerik. Hasilnya berupa tabel dengan nilai antara -1 sampai 1 untuk setiap pasangan kolom. Nilai yang mendekati 1 atau -1 menunjukkan hubungan linear yang kuat, sedangkan nilai yang mendekati 0 menunjukkan hubungan yang lemah.

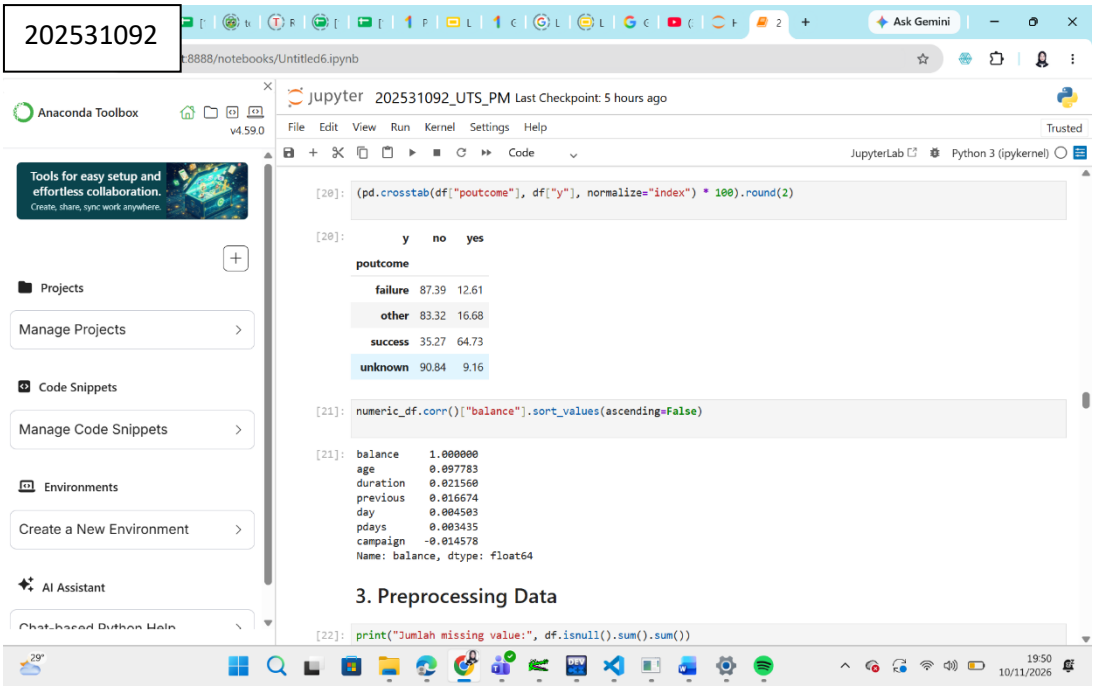
Heatmap pada gambar memberi warna pada setiap sel matriks korelasi. Warna yang lebih gelap menunjukkan nilai yang lebih besar, sedangkan warna yang lebih terang menunjukkan nilai yang lebih kecil. Heatmap memudahkan pembaca melihat pasangan variabel yang paling berkaitan tanpa harus membaca setiap angka. Pembaca dapat menggunakan heatmap ini untuk mencari pasangan fitur yang paling berkaitan sebelum keputusan pemodelan diambil.

Boxplot durasi terhadap y membandingkan sebaran durasi panggilan pada kelas no dan yes. Garis tengah pada kotak kelas yes berada lebih tinggi, yang menunjukkan median durasi yang lebih besar. Pola ini sejalan dengan intuisi bahwa percakapan yang lebih panjang berkaitan dengan peluang nasabah tertarik. Namun, durasi hanya diketahui setelah panggilan selesai, sehingga pola ini tidak dapat langsung dijadikan dasar prediksi sebelum panggilan dilakukan.

Boxplot usia terhadap y menunjukkan median yang hampir sama pada kedua kelas. Artinya, usia secara sendiri tidak membedakan keputusan nasabah dengan jelas. Temuan ini

mendorong pencarian faktor lain, seperti poutcome dan durasi, yang dibahas pada subbab berikutnya.

3.2.7 Hubungan poutcome dan korelasi balance



Gambar 3.13 Proporsi poutcome terhadap y dan korelasi balance

Gambar 3.13 menghitung proporsi keputusan nasabah berdasarkan hasil kampanye sebelumnya (poutcome) dan korelasi setiap fitur numerik terhadap balance. Hasilnya tersaji pada Tabel 3.3.

Tabel 3.3 Proporsi keputusan nasabah berdasarkan poutcome (persen)

poutcome	Tidak berlangganan (no)	Berlangganan (yes)
failure	87,39	12,61
other	83,32	16,68
success	35,27	64,73
unknown	90,84	9,16

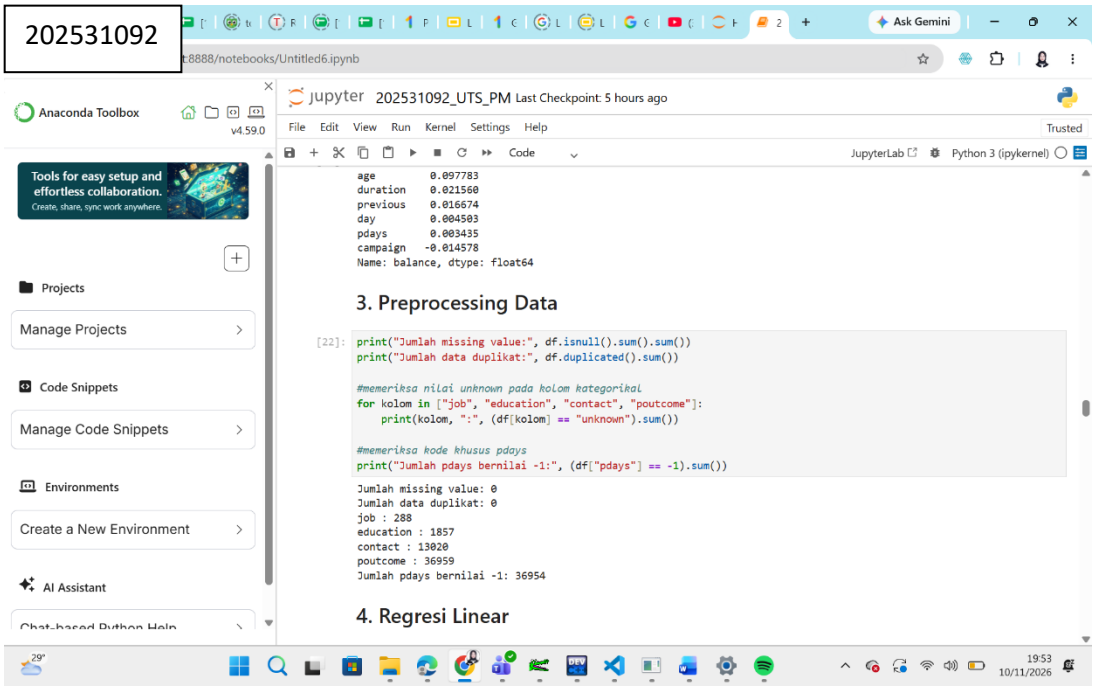
Nasabah dengan poutcome success memiliki tingkat berlangganan tertinggi, yaitu 64,73 persen. Pola ini menunjukkan bahwa riwayat keberhasilan sebelumnya berkaitan dengan keputusan berlangganan. Hubungan ini bersifat asosiasi dan tidak dapat langsung disimpulkan sebagai sebab-akibat.

Korelasi balance terhadap fitur numerik lain sangat kecil. Nilai tertingginya hanya 0,0978 pada age, sehingga hubungan linear antara balance dan fitur numerik lain tergolong lemah.

Fungsi crosstab dengan normalize="index" menghitung proporsi keputusan nasabah pada setiap kategori poutcome. Angka pada tabel dibaca per baris, sehingga setiap baris menjumlahkan 100 persen. Misalnya, pada kategori success sebanyak 64,73 persen nasabah berstatus yes, sedangkan pada kategori unknown hanya 9,16 persen. Perbedaan yang besar ini menunjukkan bahwa riwayat kampanye sebelumnya berkaitan erat dengan keputusan nasabah.

Perbedaan proporsi tersebut harus dibaca sebagai asosiasi dan bukan sebab akibat. Nasabah dengan poutcome success mungkin memiliki hubungan yang lebih baik dengan bank sejak awal, sehingga peluangnya memang lebih besar. Analisis ini tetap berguna karena memberi petunjuk bahwa poutcome perlu dipertahankan sebagai fitur pada model klasifikasi.

3.3 Praproses Data



Gambar 3.14 Pemeriksaan data sebelum pemodelan

Gambar 3.14 mengulang pemeriksaan sebelum pemodelan dan memastikan kembali bahwa data siap dipakai. Ada empat keputusan praproses yang diambil. Pertama, nilai

unknown dipertahankan sebagai kategori tersendiri karena jumlahnya besar dan tidak merepresentasikan data kosong. Kedua, data tidak dihapus walaupun ada outlier. Ketiga, nilai -1 pada pdays dipertahankan sebagai kode khusus. Keempat, kategori diubah menjadi kolom biner dengan one-hot encoding.

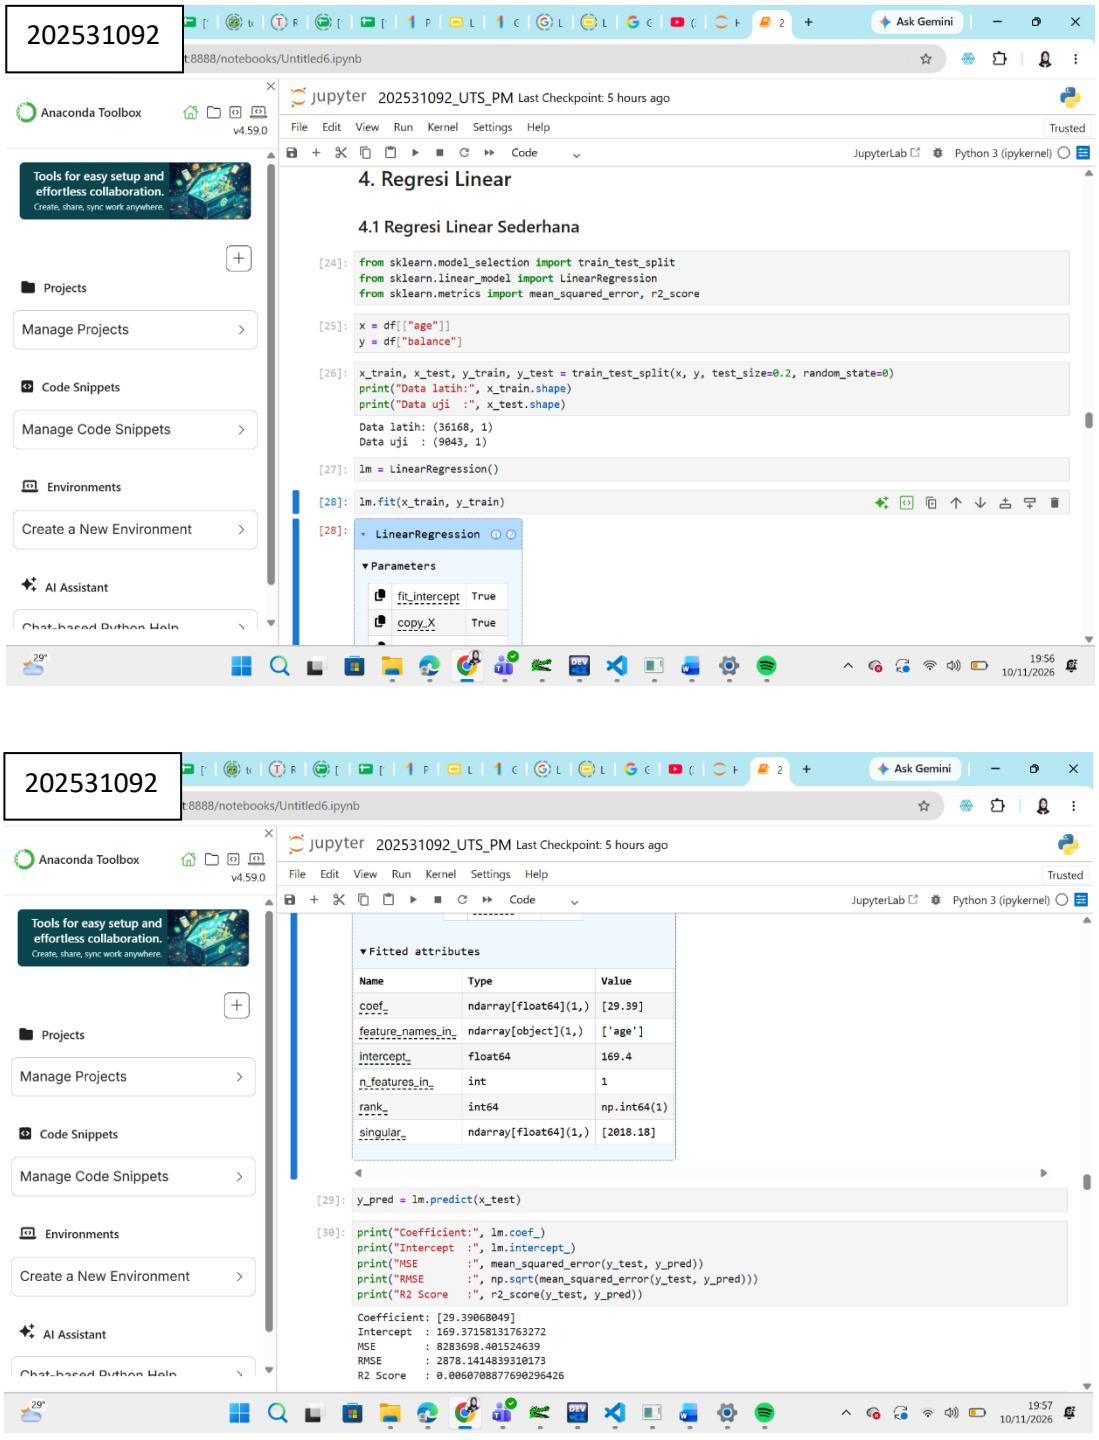
Akibat encoding, regresi linear berganda memakai 41 fitur, sedangkan decision tree memakai 51 fitur. Perbedaan jumlah ini terjadi karena regresi berganda membuang kolom balance sebagai fitur, sedangkan decision tree tetap memakai balance.

Pada bagian ini, praproses dijelaskan lebih rinci. Keputusan pertama adalah mempertahankan nilai unknown sebagai kategori tersendiri. Alasannya, nilai unknown memiliki jumlah yang besar dan menyimpan informasi bahwa data tidak tercatat. Jika nilai ini diganti dengan modus, informasi tersebut akan hilang dan model dapat salah menafsirkan nasabah yang sebenarnya tidak memiliki riwayat kampanye.

Keputusan kedua adalah tidak menghapus outlier, sebagaimana dijelaskan pada subbab 3.2.5. Keputusan ketiga adalah mempertahankan nilai -1 pada pdays sebagai kode khusus. Nilai ini tidak diubah menjadi nilai hilang karena jumlahnya besar dan kode tersebut sudah membawa arti tersendiri. Keputusan keempat adalah mengubah kategori menjadi kolom biner dengan one-hot encoding. Metode ini membuat setiap kategori menjadi kolom 0 atau 1 sehingga dapat dihitung oleh algoritma matematis.

Pada decision tree, seluruh kategori dipertahankan agar setiap aturan keputusan dapat dibaca langsung. Pada regresi berganda, satu kategori dibuang dari setiap variabel untuk menghindari masalah multikolinearitas sempurna. Dengan kata lain, jika seluruh kolom biner dari satu variabel dipakai, nilai satu kolom dapat ditebak dari kolom lainnya, sehingga koefisien tidak dapat dihitung secara stabil. Itulah alasan mengapa jumlah fitur pada kedua model berbeda.

3.4 Regresi Linear Sederhana



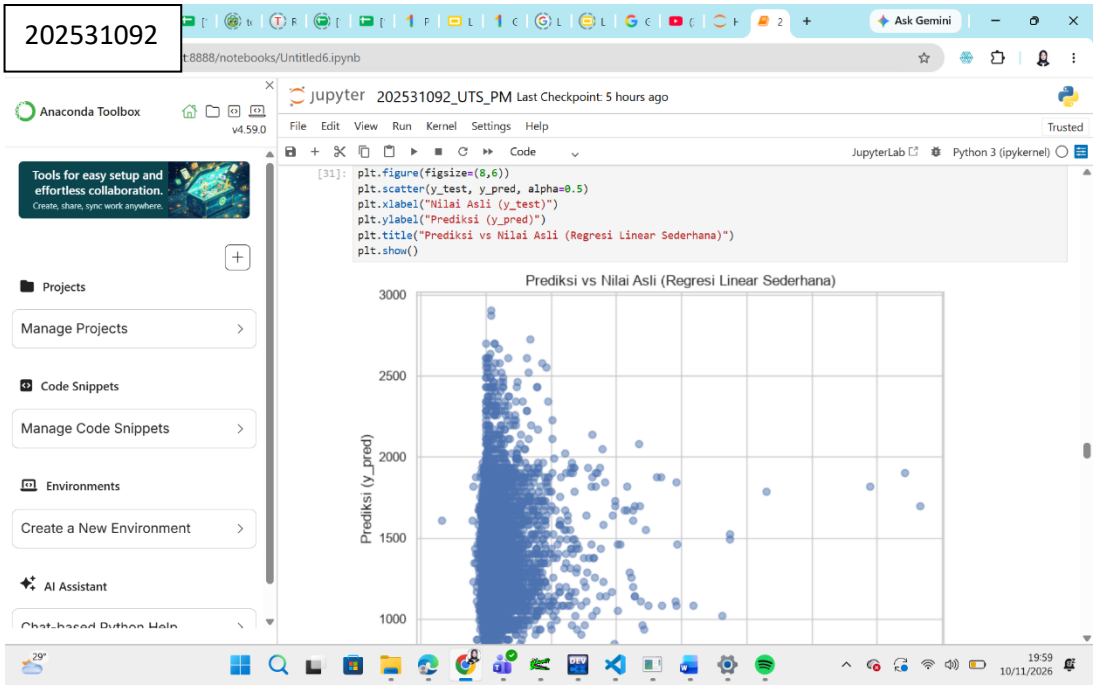
Gambar 3.15 Regresi linear sederhana

Gambar 3.16 membangun regresi linear sederhana dengan age sebagai variabel bebas dan balance sebagai variabel terikat. Data dibagi dengan perbandingan 80:20 dan random_state=0, sehingga diperoleh 36.168 data latih dan 9.043 data uji. Fungsi fit mempelajari koefisien dari data latih, lalu fungsi predict menghasilkan prediksi untuk data uji.

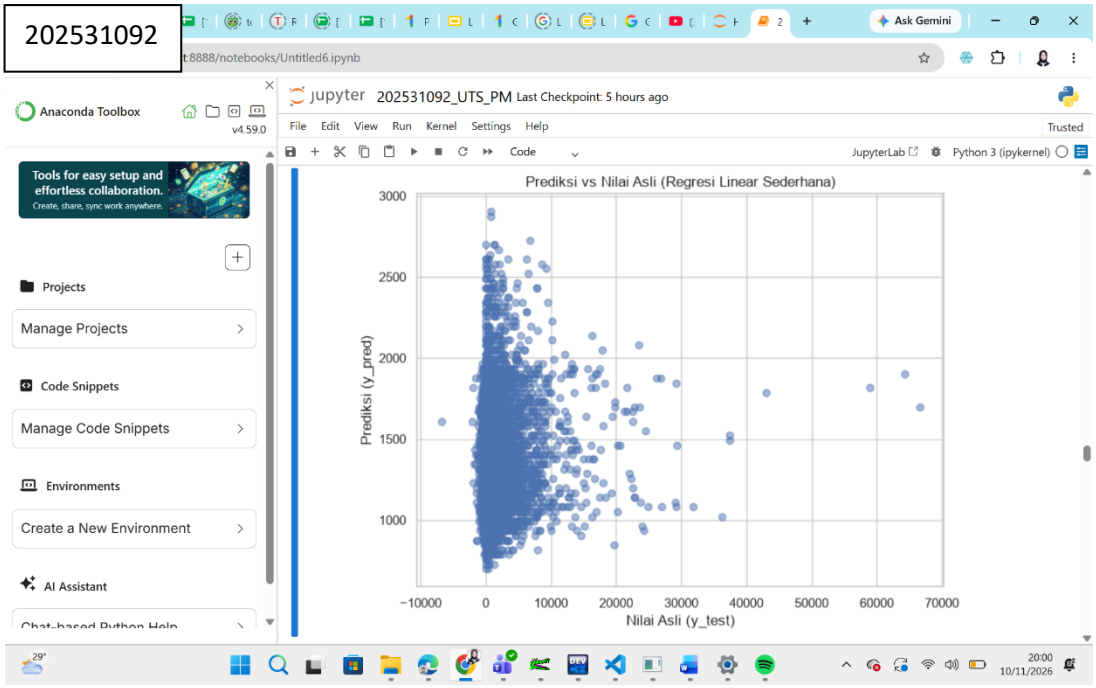
Hasil yang diperoleh adalah koefisien sebesar 29,39, intercept sebesar 169,37, MSE sebesar 8.283.698,40, RMSE sebesar 2.878,14, dan R2 sebesar 0,0061. Koefisien tersebut berarti setiap kenaikan satu tahun usia dikaitkan dengan kenaikan saldo sekitar 29,39 satuan. Namun, R2 sebesar 0,0061 menunjukkan bahwa usia hanya menjelaskan sekitar 0,61 persen variasi saldo.

RMSE sebesar 2.878,14 hampir setara dengan simpangan baku balance, yaitu 3.044,77. Dengan demikian, model belum memberi perbaikan yang berarti dibanding hanya memakai nilai rata-rata balance sebagai prediksi.

202531092



202531092



Gambar 3.16 Prediksi dan nilai asli pada regresi linear sederhana

Gambar 3.16 membandingkan nilai aktual dan nilai prediksi. Garis diagonal menunjukkan prediksi yang sempurna. Sebaran titik yang luas di sekitar area tengah menunjukkan bahwa model belum mampu mengikuti nilai aktual dengan baik.

Fungsi train_test_split membagi data menjadi dua bagian. Data latih dipakai untuk mempelajari koefisien, sedangkan data uji dipakai untuk menilai kemampuan model pada data yang belum pernah dilihat. Parameter test_size=0,2 berarti 20 persen data dialokasikan untuk pengujian. Parameter random_state=0 memastikan pembagian yang sama setiap kali kode dijalankan.

Fungsi fit mempelajari hubungan antara age dan balance dari data latih dengan metode kuadrat terkecil. Hasilnya berupa satu koefisien dan satu intersep. Koefisien 29,39 berarti setiap kenaikan satu tahun usia dikaitkan dengan kenaikan rata-rata saldo sebesar 29,39 satuan, dengan asumsi variabel lain tetap. Intersep 169,37 adalah prediksi saldo pada usia nol tahun, yang secara praktis tidak bermakna karena usia nasabah dimulai dari 18 tahun.

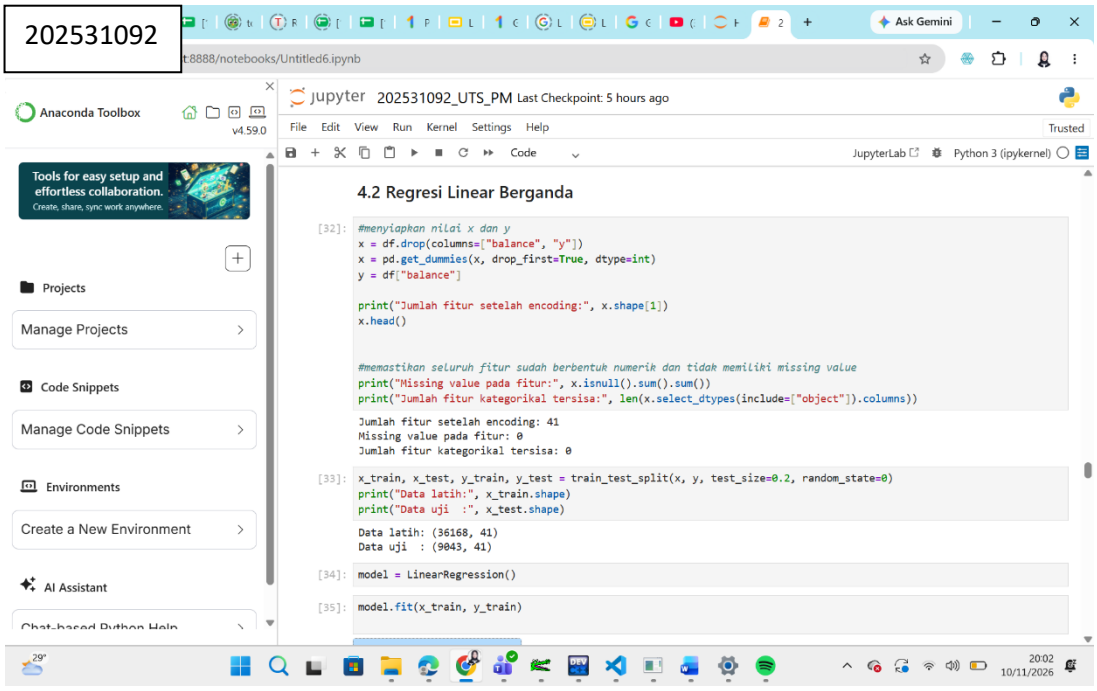
Fungsi predict menghasilkan prediksi untuk data uji. Selisih antara nilai aktual dan prediksi disebut residual. MSE dihitung dari rata-rata kuadrat residual, sehingga hasilnya sangat besar karena satuannya adalah satuan saldo yang dikuadratkan. Karena itu, RMSE sebesar 2.878,14 lebih mudah dibaca karena berada pada satuan yang sama dengan saldo. Nilai R2 sebesar 0,0061 menunjukkan bahwa model hanya menjelaskan sekitar 0,61 persen variasi saldo.

Pembandingan RMSE dengan simpangan baku balance memberi gambaran yang lebih jelas. Simpangan baku sebesar 3.044,77 adalah error jika setiap nasabah diprediksi dengan rata-rata saldo. RMSE model sebesar 2.878,14 hanya sedikit lebih kecil, sehingga perbaikan yang diberikan oleh usia sangat kecil.

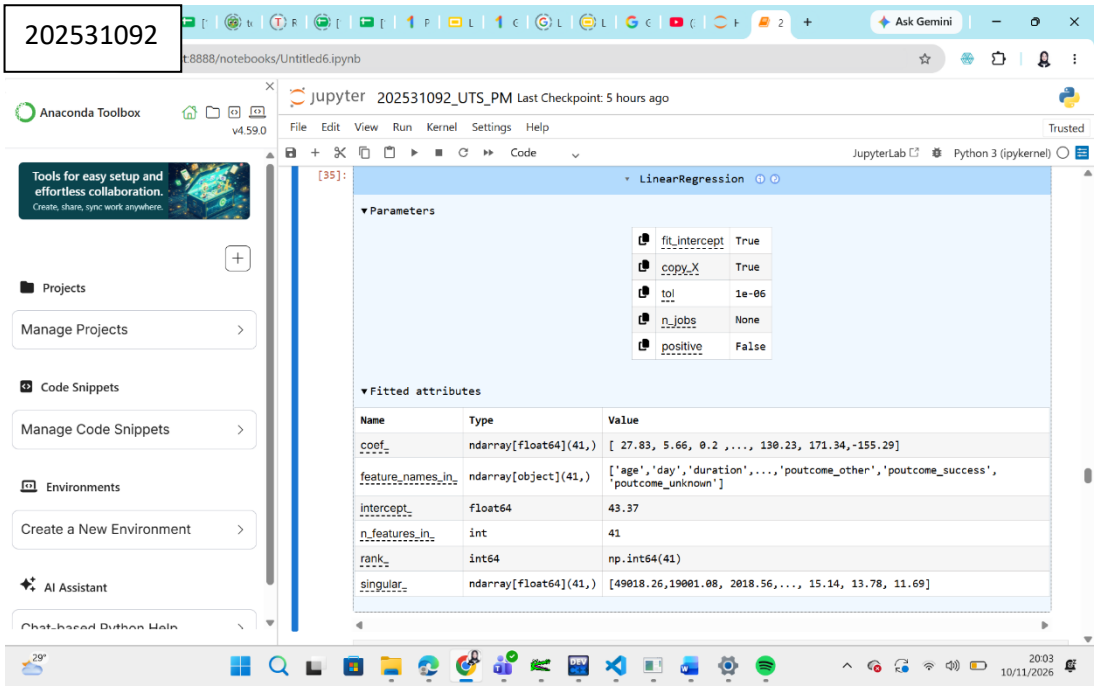
Grafik pada gambar menampilkan nilai aktual pada sumbu horizontal dan nilai prediksi pada sumbu vertikal. Garis diagonal menunjukkan prediksi yang sempurna. Titik yang berada dekat garis tersebut menunjukkan prediksi yang baik. Pada grafik ini, titik-titik tersebar luas di sekitar garis, dan banyak nilai aktual yang besar tidak terwakili dalam prediksi. Pola ini sesuai dengan nilai R2 yang rendah.

3.5 Regresi Linear Berganda

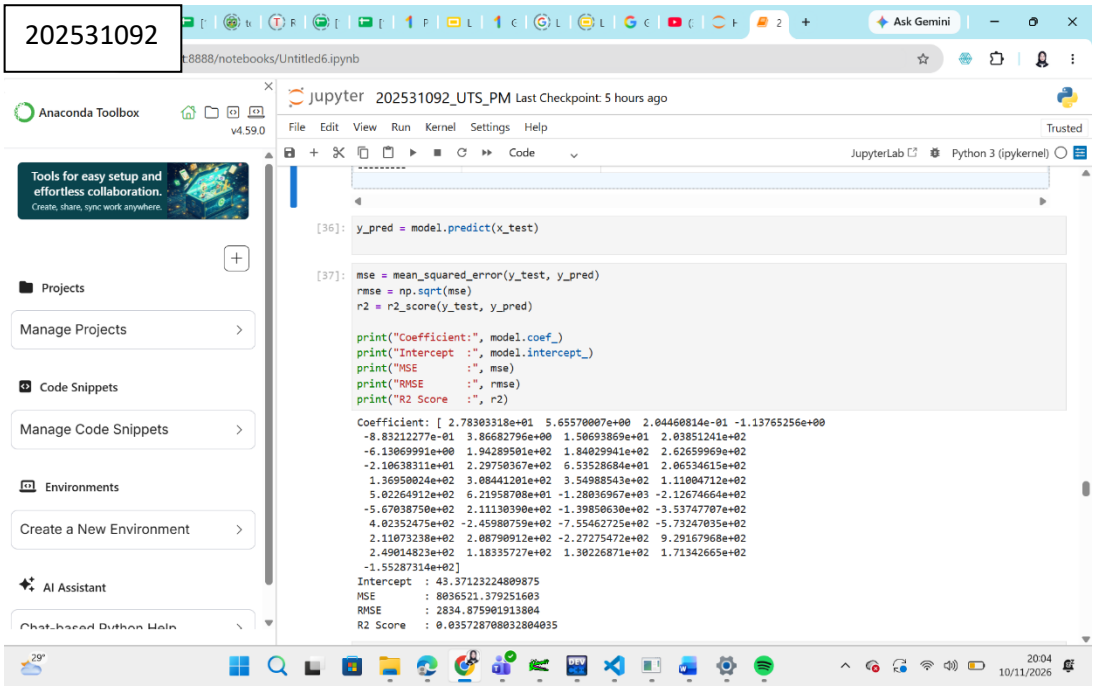
202531092



202531092



202531092



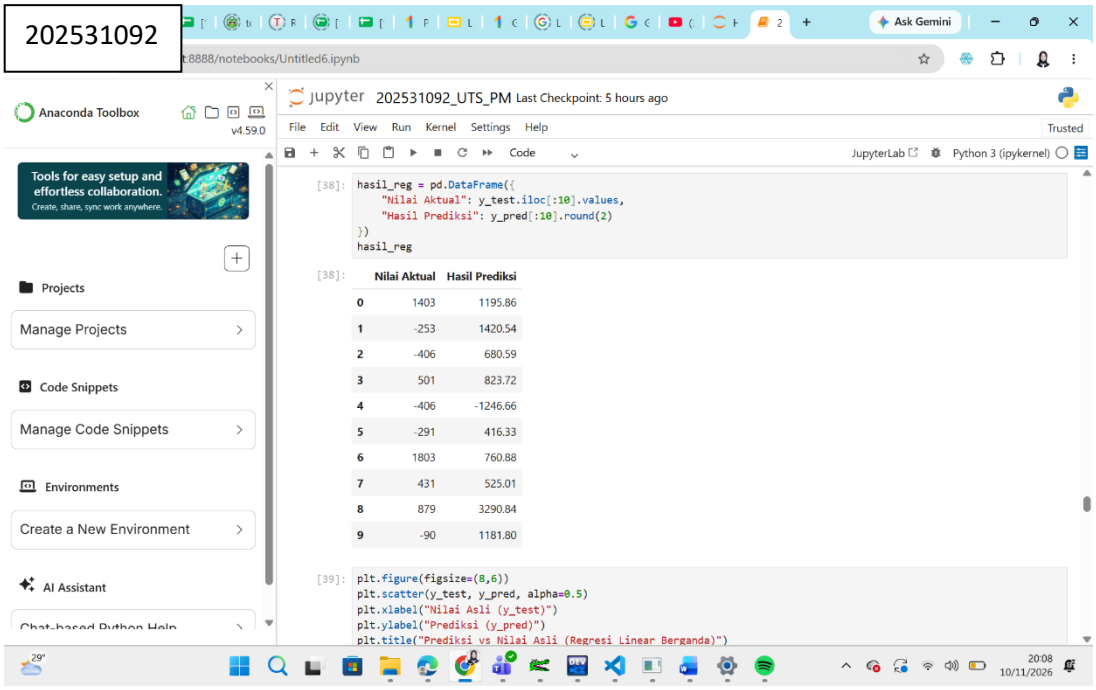
Gambar 3.17 Regresi linear berganda

Gambar 3.17 membangun regresi linear berganda dengan seluruh fitur kecuali balance dan y. Fungsi get_dummies dengan drop_first=True mengubah kolom kategorik menjadi kolom biner dan membuang satu kategori per kolom. Jumlah fitur setelah encoding menjadi 41, dengan pembagian data yang sama seperti regresi sederhana, yaitu 36.168 data latih dan 9.043 data uji.

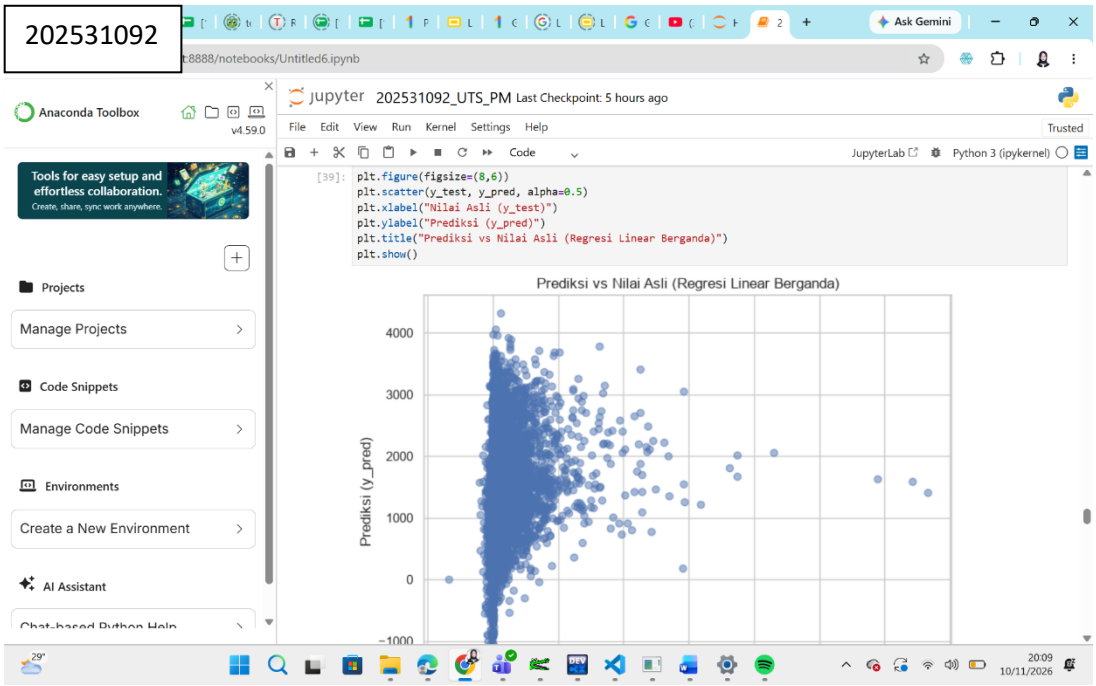
Pemeriksaan pada kode menunjukkan tidak ada nilai hilang pada fitur dan tidak ada kolom kategorik yang tersisa. Koefisien setiap fitur berkisar dari -1.280,37 sampai 929,17, dengan intercept sebesar 43,37. Hasil evaluasi menunjukkan MSE sebesar 8.036.521,38, RMSE sebesar 2.834,88, dan R2 sebesar 0,0357 atau 3,57 persen.

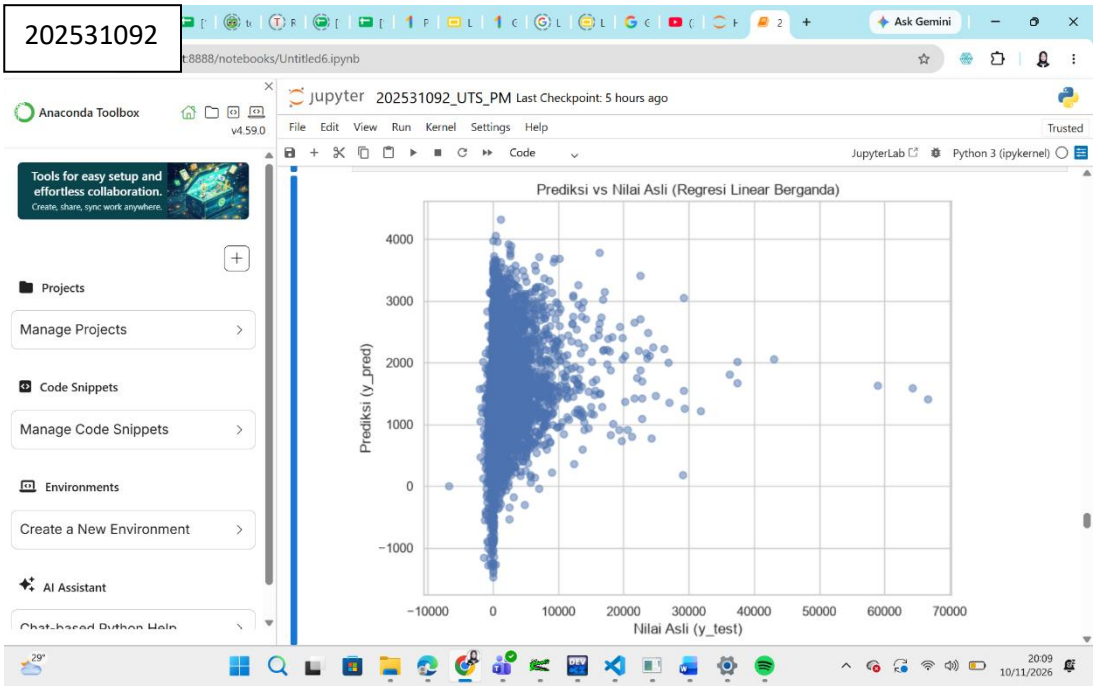
Penambahan fitur lain hanya menaikkan R2 dari 0,0061 menjadi 0,0357. Peningkatan ini kecil. Dengan demikian, kumpulan fitur pada dataset ini belum cukup kuat untuk menjelaskan saldo nasabah secara linear.

202531092



202531092





Gambar 3.19 Tabel hasil prediksi dan grafik regresi berganda

Gambar 3.19 menampilkan sepuluh contoh nilai aktual dan nilai prediksi dari data uji. Hasilnya tersaji pada Tabel 3.4. Pada indeks ke-8, nilai aktual 879 diprediksi sebesar 3.290,84. Pada indeks ke-4, nilai aktual -406 diprediksi sebesar -1.246,66. Selisih seperti ini menunjukkan bahwa prediksi model cenderung menyebar tanpa mengikuti nilai aktual.

Tabel 3.4 Nilai aktual dan prediksi pada sepuluh data uji regresi berganda

Indeks	Nilai aktual	Hasil prediksi
0	1.403	1.195,86
1	-253	1.420,54
2	-406	680,59
3	501	823,72
4	-406	-1.246,66
5	-291	416,33

Indeks	Nilai aktual	Hasil prediksi
6	1.803	760,88
7	431	525,01
8	879	3.290,84
9	-90	1.181,80

Tabel 3.5 Ringkasan metrik regresi linear

Model	MSE	RMSE	R2
Regresi linear sederhana (age)	8.283.698,40	2.878,14	0,0061
Regresi linear berganda (seluruh fitur)	8.036.521,38	2.834,88	0,0357

Pada regresi berganda, fitur kategorik diubah menjadi kolom biner dengan get_dummies dan drop_first=True. Kolom balance dan y dikeluarkan dari fitur. Hasilnya adalah 41 fitur yang dipakai untuk menghitung koefisien. Algoritma regresi hanya menerima angka, sehingga seluruh kategori harus sudah berbentuk kolom biner sebelum fit dipanggil.

Koefisien setiap fitur berkisar antara -1.280,37 sampai 929,17. Rentang yang lebar ini menunjukkan bahwa beberapa fitur memiliki pengaruh yang sangat besar pada prediksi. Namun, besar koefisien harus dibaca bersama skala fitur dan tingkat signifikansinya. Fitur biner yang bernilai 0 atau 1 secara alami memiliki koefisien yang berbeda skalanya dibanding fitur numerik seperti age.

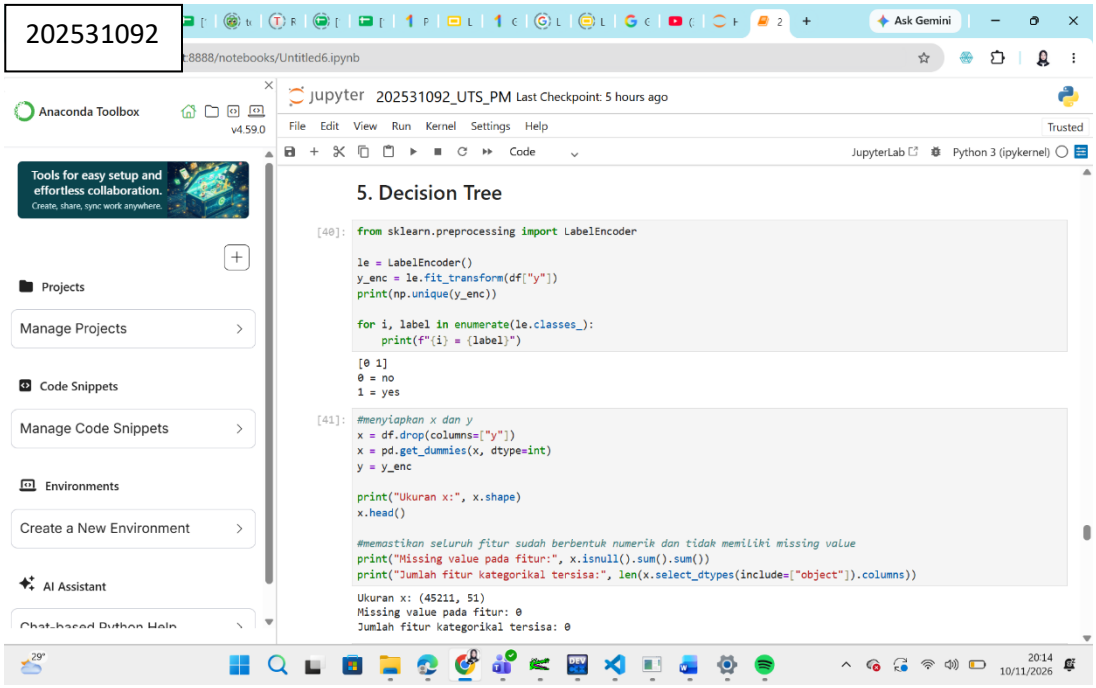
Intersep sebesar 43,37 adalah nilai prediksi ketika seluruh fitur bernilai nol atau kategori acuan. Hasil evaluasi menunjukkan MSE sebesar 8.036.521,38, RMSE sebesar 2.834,88, dan R2 sebesar 0,0357 atau 3,57 persen. Nilai R2 ini sedikit lebih tinggi dibanding regresi sederhana, tetapi peningkatannya masih sangat kecil.

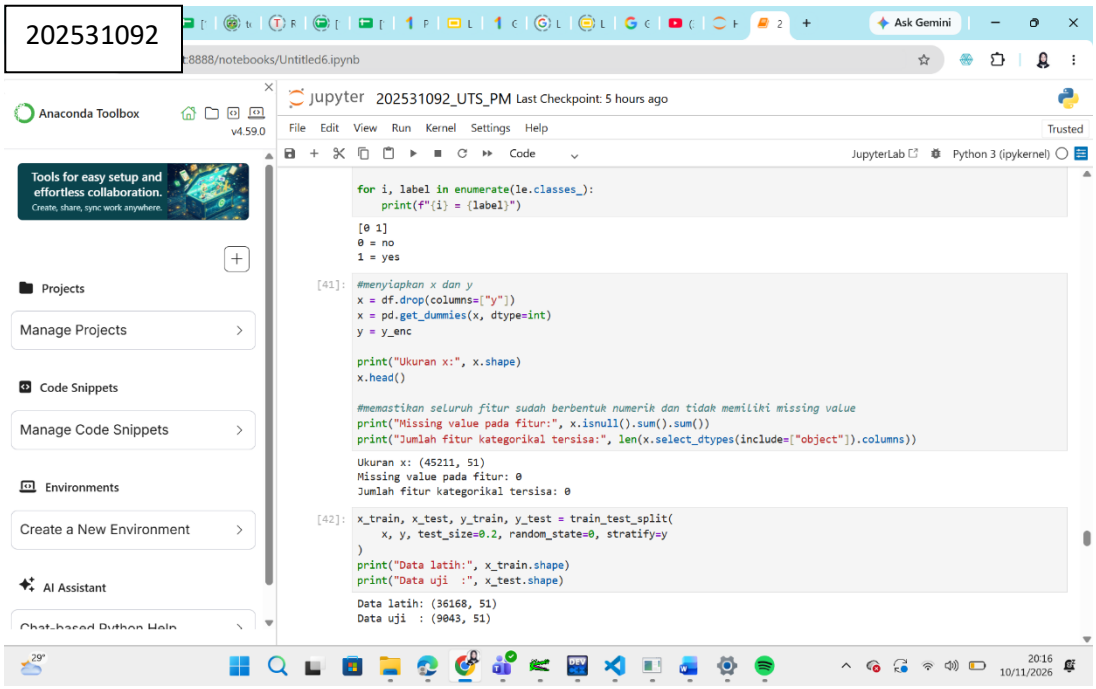
Tabel 3.4 menampilkan sepuluh contoh data uji. Pada indeks 8, nilai aktual 879 diprediksi sebesar 3.290,84, sehingga selisihnya sekitar 2.412. Pada indeks 4, nilai aktual -406 diprediksi sebesar -1.246,66, sehingga selisihnya sekitar 841. Contoh-contoh ini memperlihatkan bahwa model dapat meleset cukup jauh pada beberapa nasabah, sedangkan pada nasabah lain prediksinya masih mendekati nilai aktual.

Gambar grafik regresi berganda memperlihatkan pola yang sama dengan regresi sederhana. Prediksi berkumpul pada rentang nilai yang sempit dan tidak mampu menangkap saldo yang sangat tinggi maupun saldo yang negatif. Tabel 3.5 merangkum perbandingan

kedua model. Penurunan RMSE dari 2.878,14 menjadi 2.834,88 hanya sekitar 1,5 persen, sehingga penambahan fitur belum memberi perbaikan yang berarti.

3.6 Decision Tree





Gambar 3.20 Encoding label dan pembagian data untuk decision tree

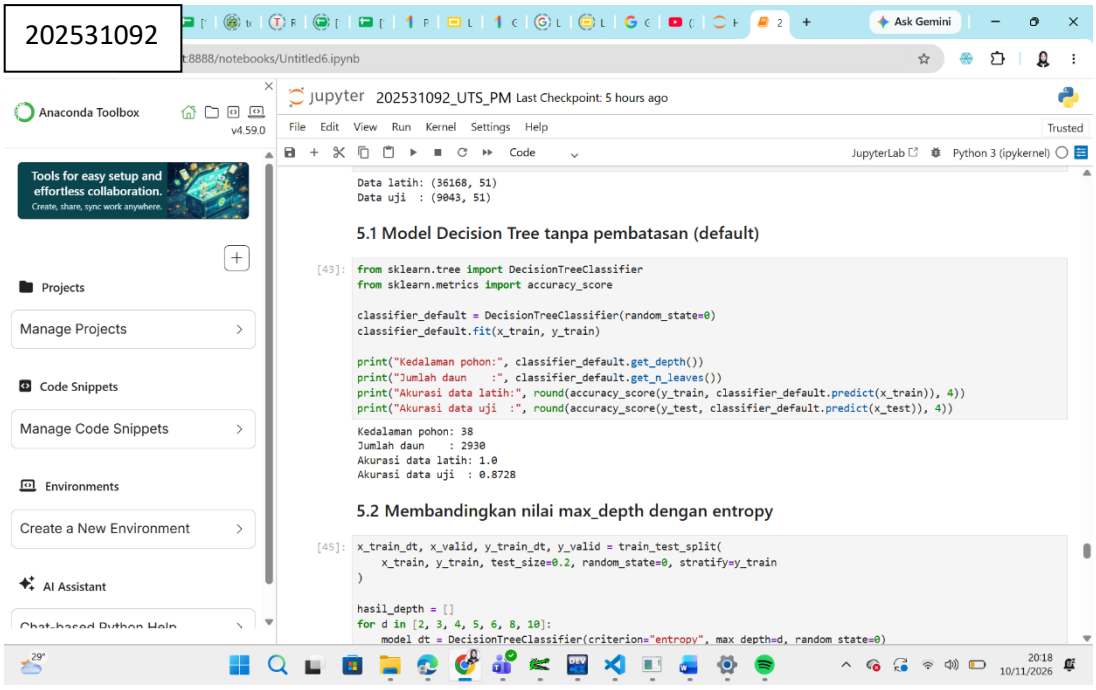
Gambar 3.20 menyiapkan data untuk klasifikasi. LabelEncoder mengubah label no menjadi 0 dan yes menjadi 1. Fungsi get_dummies mengubah seluruh fitur kategorik menjadi kolom biner, sehingga diperoleh 51 fitur. Parameter stratify=y menjaga proporsi kelas yes dan no tetap mirip di data latih dan data uji.

Decision tree tidak memerlukan asumsi hubungan linear, sehingga kolom balance tetap dipakai sebagai fitur pada tahap ini.

Kode pada sel ini mengubah label y menjadi angka. LabelEncoder memberikan nilai 0 untuk no dan 1 untuk yes. Decision tree dari scikit-learn membutuhkan target berupa angka, sehingga langkah ini wajib dilakukan. Selanjutnya, fitur kategorik diubah menjadi kolom biner dengan get_dummies. Berbeda dengan regresi, pada decision tree seluruh kategori dipertahankan agar aturan yang dihasilkan dapat dibaca lengkap.

Parameter stratify=y pada train_test_split menjaga agar proporsi kelas yes dan no tetap mirip di data latih dan data uji. Tanpa parameter ini, data uji dapat memperoleh proporsi yang berbeda dari data latih, sehingga hasil evaluasi menjadi kurang adil. Decision tree tidak memerlukan asumsi linearitas, sehingga kolom balance tetap dipakai sebagai fitur. Jumlah fitur setelah encoding menjadi 51.

3.6.1 Model tanpa pembatasan kedalaman

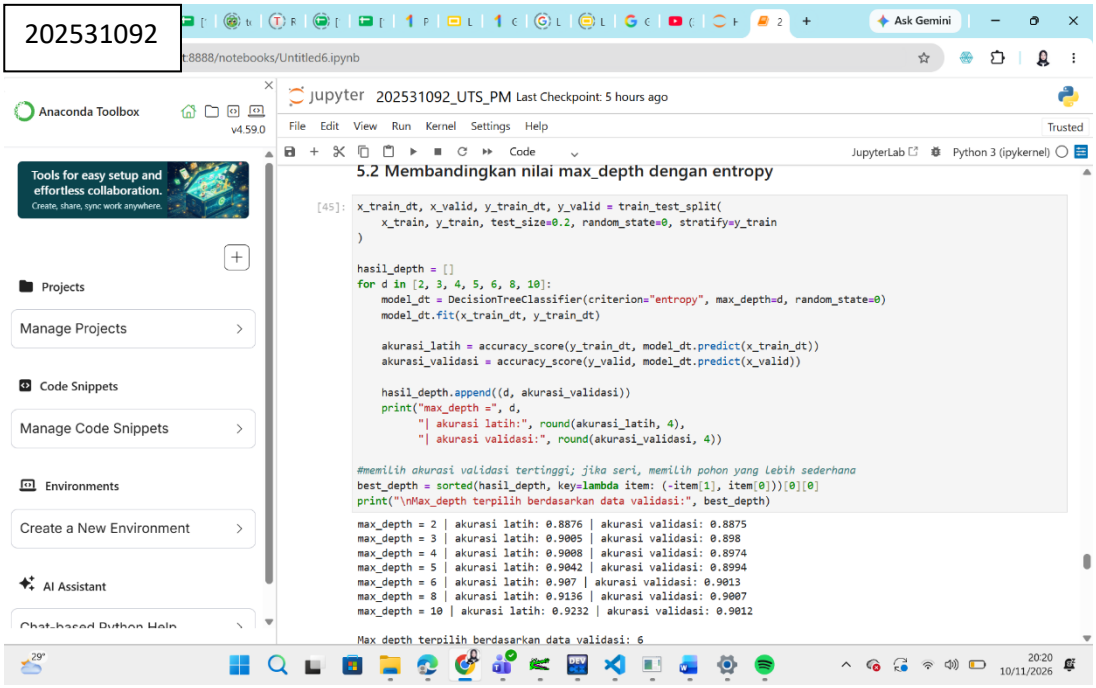


Gambar 3.21 Decision tree tanpa pembatasan kedalaman

Gambar 3.21 melatih decision tree tanpa pembatasan kedalaman. Hasilnya, pohon mencapai kedalaman 38 dengan 2.930 daun. Akurasi pada data latih mencapai 1,0, tetapi akurasi pada data uji hanya 0,8728. Selisih sebesar 0,1272 ini menjadi tanda overfitting. Pohon yang terlalu dalam menghafal data latih sehingga kurang mampu menggeneralisasi data baru, sesuai dengan temuan Halabaku dan Bytyçi (2024).

Kode tanpa pembatasan kedalaman menghasilkan pohon dengan kedalaman 38 dan 2.930 daun. Jumlah daun yang sangat besar ini menandakan bahwa pohon membuat banyak sekali aturan kecil yang sangat spesifik pada data latih. Akibatnya, akurasi latih mencapai 1,0, tetapi akurasi uji hanya 0,8728. Selisih sekitar 0,127 ini menjadi tanda bahwa pohon telah menghafal data latih.

3.6.2 Pemilihan max_depth berdasarkan data validasi



Gambar 3.22 Pemilihan max_depth berdasarkan data validasi

Gambar 3.22 membagi data latih lagi menjadi 28.934 data latih dan 7.234 data validasi dengan stratifikasi. Setiap kandidat max_depth dilatih pada data latih lalu diuji pada data validasi. Hasilnya tersaji pada Tabel 3.6.

Tabel 3.6 Akurasi decision tree berdasarkan max_depth

max_depth	Akurasi data latih	Akurasi data validasi
2	0,8876	0,8875
3	0,9005	0,8980
4	0,9008	0,8974
5	0,9042	0,8994
6	0,9070	0,9013
8	0,9136	0,9007
10	0,9232	0,9012

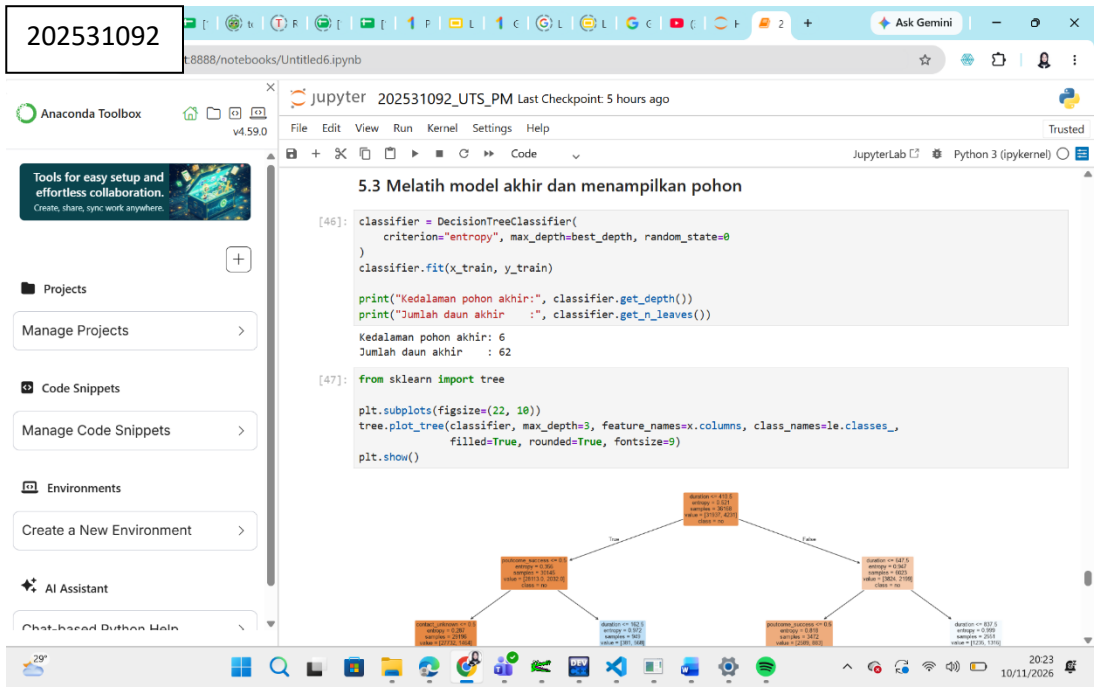
Nilai max_depth 6 dipilih karena memiliki akurasi validasi tertinggi, yaitu 0,9013. Pada max_depth 8 dan 10, akurasi data latih naik cukup tajam, tetapi akurasi validasi tidak ikut naik. Pola ini menjadi tanda bahwa pohon yang lebih dalam mulai menghafal data latih.

Pada tahap pemilihan max_depth, data latih dibagi lagi menjadi 28.934 data latih dan 7.234 data validasi. Setiap kandidat kedalaman dilatih pada data latih dan diuji pada data validasi. Tabel 3.6 menunjukkan bahwa akurasi latih naik terus seiring kedalaman, sedangkan akurasi validasi naik sampai kedalaman 6 lalu cenderung mendatar. Kedalaman 6 dipilih karena menghasilkan akurasi validasi tertinggi, yaitu 0,9013.

Pemilihan dilakukan pada data validasi agar data uji tetap bersih. Jika max_depth dipilih berdasarkan data uji, angka akurasi uji menjadi bias karena model seolah sudah melihat data tersebut saat memilih parameter. Pendekatan ini sejalan dengan prinsip evaluasi model yang baik dan menjadi alasan utama pemisahan tiga bagian data.

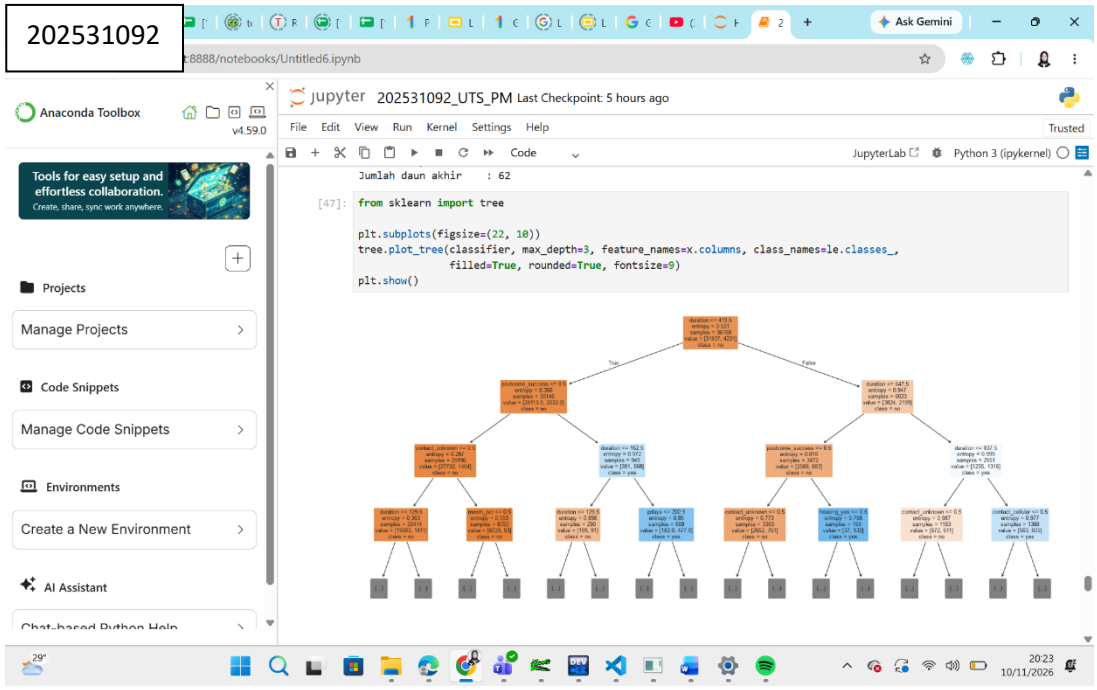
3.6.3 Pelatihan model akhir dan visualisasi pohon

Parameter criterion="entropy" membuat pohon memilih pemisahan berdasarkan information gain. Pada setiap simpul, algoritma mencoba semua kemungkinan pemisahan dan memilih yang paling mengurangi ketidakpastian kelas. Parameter random_state=0 memastikan hasil pohon selalu sama setiap kali dijalankan.



Gambar 3.23 Pelatihan model akhir dan visualisasi pohon

Gambar 3.24 melatih model akhir dengan criterion="entropy" dan max_depth=6. Pohon yang dihasilkan memiliki kedalaman 6 dan 62 daun. Visualisasi pada Gambar 3.25 hanya menampilkan tiga tingkat pertama agar gambar tetap terbaca. Parameter filled=True mewarnai setiap simpul sesuai kelas mayoritasnya.



Gambar 3.24 Visualisasi pohon keputusan (tiga tingkat pertama)

Model akhir dilatih dengan criterion="entropy" dan max_depth=6 pada data latih. Pohon yang terbentuk memiliki kedalaman 6 dan 62 daun. Jumlah daun yang jauh lebih sedikit dibanding model default menunjukkan bahwa pohon menjadi lebih sederhana dan lebih mudah dibaca.

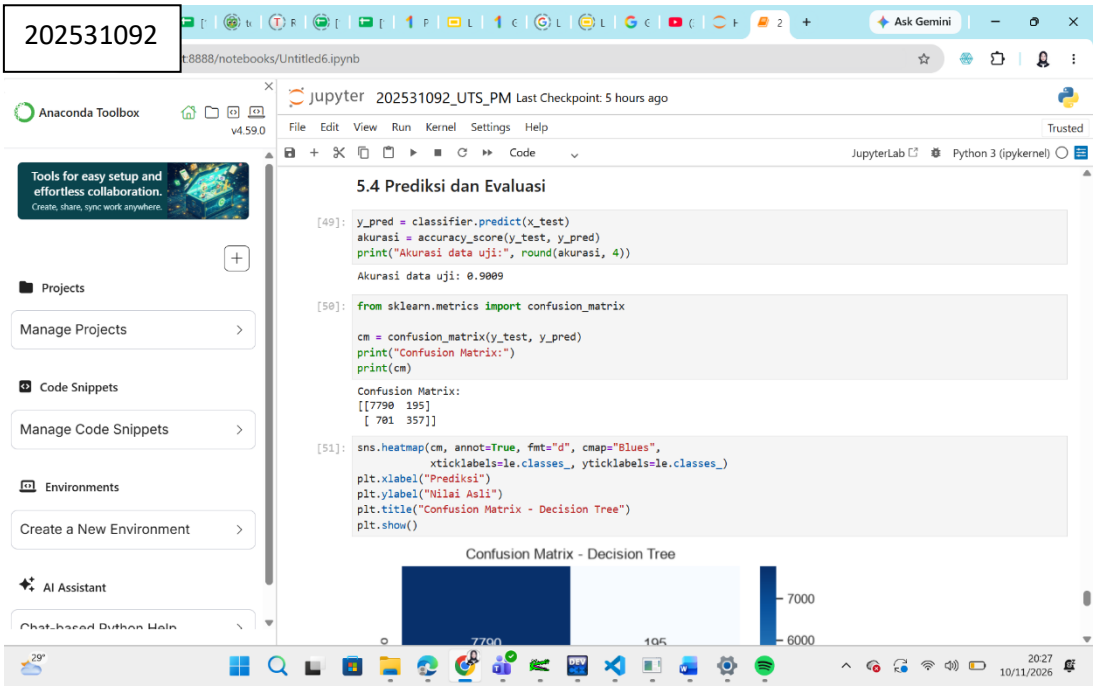
Gambar pohon hanya menampilkan tiga tingkat pertama agar tulisan tetap terbaca. Setiap simpul menampilkan kondisi pemisahan, nilai entropy, jumlah sampel, dan distribusi kelas. Parameter filled=True mewarnai simpul sesuai kelas mayoritasnya, sehingga pembaca dapat melihat jalur mana yang menghasilkan prediksi yes atau no. Dengan membaca pohon dari akar sampai daun, setiap prediksi dapat dijelaskan dengan aturan yang jelas.

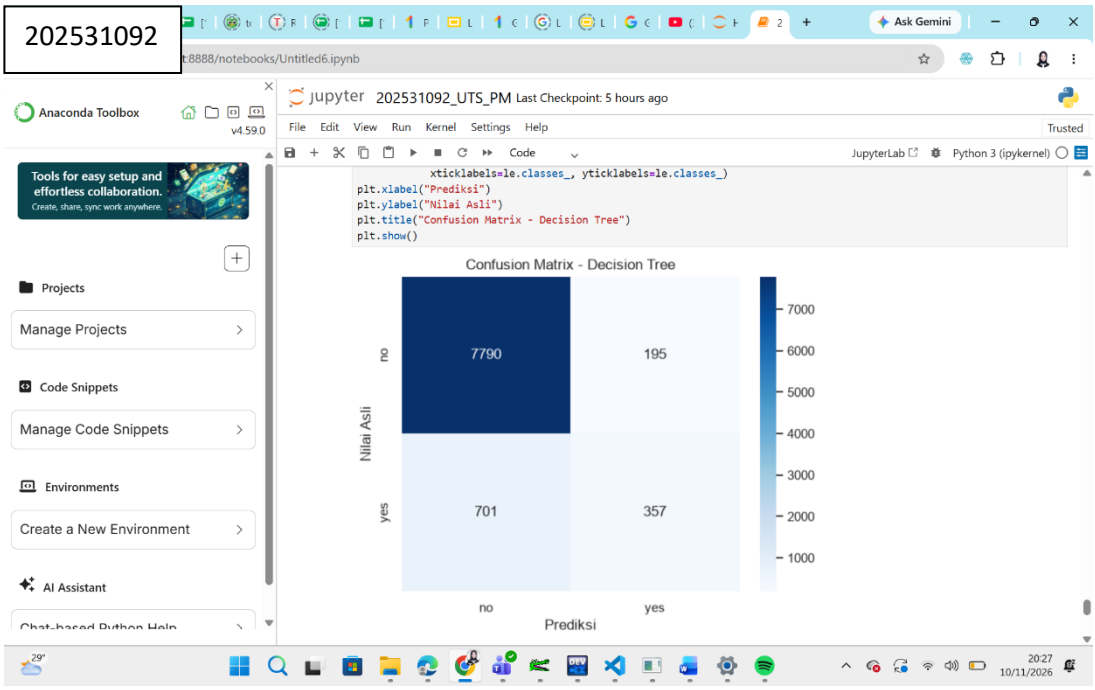
Prediksi dilakukan pada data uji dan menghasilkan akurasi sebesar 0,9009. Confusion matrix pada Tabel 3.7 membaca hasil dalam empat sel. Sel atas kiri berisi 7.790 nasabah no yang diprediksi no, yaitu true negative. Sel atas kanan berisi 195 nasabah no yang diprediksi yes, yaitu false positive. Sel bawah kiri berisi 701 nasabah yes yang diprediksi no, yaitu false negative. Sel bawah kanan berisi 357 nasabah yes yang diprediksi yes, yaitu true positive.

Dari keempat sel tersebut, presisi kelas yes dihitung dari 357 dibagi 552, yaitu sekitar 0,6467. Recall kelas yes dihitung dari 357 dibagi 1.058, yaitu sekitar 0,3374. F1-score kelas yes sebesar 0,4435 menggabungkan kedua nilai tersebut. Tabel 3.8 merangkum metrik per kelas. Kelas no memiliki presisi 0,9174 dan recall 0,9756, sehingga model sangat baik dalam mengenali nasabah yang tidak berlangganan.

Heatmap confusion matrix memperjelas bahwa sel false negative paling besar setelah sel true negative. Artinya, banyak nasabah yang sebenarnya berlangganan tidak terdeteksi oleh model. Pada konteks kampanye pemasaran, kondisi ini berarti peluang bisnis yang terlewat, sehingga recall kelas yes perlu mendapat perhatian khusus pada pengembangan berikutnya.

3.6.4 Prediksi dan evaluasi





Gambar 3.25 Prediksi, confusion matrix, dan heatmap

Gambar 3.25 menghitung akurasi dan confusion matrix pada data uji. Akurasi model akhir adalah 0,9009 atau 90,09 persen. Hasil confusion matrix tersaji pada Tabel 3.7, sedangkan metrik per kelas tersaji pada Tabel 3.8.

Tabel 3.7 Confusion matrix decision tree pada data uji

Nilai aktual \ Prediksi	no	yes
no	7.790	195
yes	701	357

Tabel 3.8 Presisi, recall, dan F1-score per kelas

Kelas	Presisi	Recall	F1-score
no	0,9174	0,9756	0,9456
yes	0,6467	0,3374	0,4435

Akurasi model sebesar 0,9009 lebih tinggi dibanding baseline 0,8830 yang diperoleh jika semua nasabah diprediksi no. Namun, recall pada kelas yes hanya 0,3374. Dari 1.058 nasabah yang sebenarnya berlangganan, model hanya menangkap 357 nasabah. Presisi kelas yes sebesar 0,6467 berarti dari 552 nasabah yang diprediksi yes, sebanyak 357 nasabah benar-benar berlangganan.

Hasil pada Bab 3.4 sampai 3.6 dapat dirangkum menjadi tiga temuan utama. Temuan pertama adalah bahwa regresi linear tidak cocok untuk memprediksi saldo dengan fitur yang tersedia. Temuan kedua adalah bahwa decision tree mampu memprediksi keputusan nasabah dengan akurasi yang cukup baik, tetapi kemampuan mengenali kelas yes masih terbatas. Temuan ketiga adalah bahwa pembatasan kedalaman terbukti mengurangi overfitting, sebagaimana terlihat dari selisih akurasi latih dan uji yang mengecil.

Pada regresi, kualitas prediksi sangat dipengaruhi distribusi target yang condong dan keberadaan outlier. Nilai saldo yang sangat besar membuat MSE mudah terdongkrak oleh beberapa prediksi yang meleset jauh. Transformasi logaritma pada balance atau penanganan outlier dengan metode yang lebih khusus dapat dicoba untuk melihat apakah pola linear menjadi lebih jelas.

Pada klasifikasi, akurasi 0,9009 terlihat tinggi, tetapi perbandingan dengan baseline 0,8830 menunjukkan bahwa peningkatannya hanya sekitar 2 persen. Pembacaan presisi dan recall memperlihatkan bahwa model masih melewatkan sekitar dua pertiga nasabah yang berlangganan. Karena itu, akurasi tidak boleh menjadi satu-satunya ukuran keberhasilan model pada data yang tidak seimbang.

Ada catatan penting pada fitur duration. Durasi panggilan baru diketahui setelah panggilan selesai, sehingga fitur ini tidak tersedia pada saat keputusan kampanye dibuat. Sebagian akurasi model kemungkinan berasal dari fitur tersebut. Untuk penggunaan yang lebih realistis, fitur duration sebaiknya dikeluarkan dari model dan hasilnya dibandingkan kembali.

Pembahasan ini juga sejalan dengan kajian pustaka. Halabaku dan Bytyçi (2024) membahas overfitting pada decision tree, sedangkan Hasnataeni dkk. (2025) menunjukkan kesulitan model pada data yang tidak seimbang. Abidin dkk. (2025) menggunakan SMOTE untuk mengatasi ketidakseimbangan kelas pada data pemasaran. Teknik tersebut belum diterapkan pada kode final dan menjadi langkah lanjutan yang paling jelas.

3.7 Pembahasan Hasil

Kedua model regresi menunjukkan bahwa saldo nasabah sulit diprediksi dari fitur dataset ini. Distribusi balance yang sangat condong dan keberadaan outlier membuat MSE sangat dipengaruhi oleh nilai ekstrem. Beberapa prediksi yang meleset jauh akan menaikkan error secara signifikan. Transformasi target, misalnya logaritma, atau penanganan outlier dapat dicoba pada pengembangan selanjutnya.

Decision tree memberikan hasil yang lebih baik untuk tugas klasifikasi dengan akurasi uji 0,9009. Pembatasan kedalaman menurunkan selisih antara akurasi latih dan akurasi uji,

dari 0,1272 pada model default menjadi selisih yang jauh lebih kecil pada model akhir. Hasil ini sejalan dengan pembahasan overfitting pada Halabaku dan Bytyçi (2024).

Ada satu catatan penting pada fitur duration. Nilai durasi baru diketahui setelah panggilan selesai, sehingga pada penerapan nyata fitur ini tidak tersedia ketika prediksi dibuat. Sebagian akurasi model kemungkinan berasal dari fitur tersebut. Untuk penggunaan yang lebih realistis, fitur duration sebaiknya dikeluarkan dari model dan akurasinya dibandingkan kembali.

Untuk kelas yes, recall sebesar 0,3374 menunjukkan bahwa model masih melewatkan banyak nasabah potensial. Abidin dkk. (2025) menggunakan SMOTE untuk mengatasi ketidakseimbangan kelas, sedangkan Hasnataeni dkk. (2025) membandingkan beberapa metode ensemble pada data yang tidak seimbang. Teknik tersebut belum diterapkan pada kode final ini dan dapat menjadi langkah lanjutan.

BAB IV
PENUTUP

4.1 Kesimpulan

Kesimpulan berikut disusun dari hasil pelaksanaan praktikum pada Bab III dan dikaitkan dengan landasan teori pada Bab II. Setiap poin menjelaskan satu aspek dari proses dan hasil praktikum.

1. **Pemahaman dataset.** Dataset berisi 45.211 nasabah dengan 17 kolom dan tidak memiliki nilai hilang maupun data duplikat. Kelas target yes hanya 11,7 persen, sehingga data tergolong tidak seimbang. Kondisi ini sejalan dengan materi tentang pentingnya memeriksa distribusi kelas sebelum pemodelan, karena distribusi yang timpang dapat membuat akurasi terlihat tinggi tanpa model benar-benar mampu mengenali kelas minoritas.
2. **Eksplorasi data dan pencilan.** Distribusi balance sangat condong ke kanan dengan median 448 dan rata-rata 1.362,27. Metode IQR menandai 10,46 persen data sebagai outlier. Nilai tersebut tidak dihapus karena saldo besar merupakan kondisi nyata pada nasabah bank. Pola ini sesuai dengan teori bahwa pencilan perlu dikenali, tetapi tidak selalu harus dibuang.
3. **Praproses data.** Variabel kategorik diubah menjadi kolom biner dengan one-hot encoding. Regresi berganda memakai 41 fitur dengan drop_first=True, sedangkan decision tree memakai 51 fitur. Pembagian data dilakukan dengan perbandingan 80:20, dan decision tree memakai stratifikasi agar proporsi kelas tetap terjaga di data latih dan data uji.
4. **Regresi linear sederhana.** Usia hanya menjelaskan sekitar 0,61 persen variasi saldo (R2 0,0061) dengan koefisien 29,39. RMSE sebesar 2.878,14 hampir setara dengan simpangan baku balance, sehingga model belum memberi perbaikan berarti dibanding nilai rata-rata. Hasil ini menunjukkan bahwa nilai R2 yang rendah tidak dapat diabaikan begitu saja ketika membaca kualitas regresi.
5. **Regresi linear berganda.** Penambahan fitur menaikkan R2 menjadi 0,0357 dengan RMSE 2.834,88. Peningkatan ini kecil, sehingga kumpulan fitur pada dataset ini belum cukup kuat untuk menjelaskan saldo nasabah secara linear. Teori regresi linear menuntut hubungan yang cukup kuat antara variabel bebas dan variabel terikat, dan kondisi tersebut belum terpenuhi pada data ini.

6. **Decision tree dan overfitting.** Model tanpa pembatasan kedalaman mencapai akurasi latih 1,0, tetapi akurasi uji hanya 0,8728. Selisih ini menjadi tanda overfitting. Pemilihan max_depth 6 berdasarkan data validasi menghasilkan akurasi uji 0,9009 dengan 62 daun. Hasil ini sesuai dengan teori bahwa pembatasan kompleksitas pohon dapat mengurangi overfitting.
7. **Evaluasi model klasifikasi.** Akurasi sebesar 90,09 persen hanya sedikit di atas baseline 88,30 persen yang diperoleh dengan selalu menjawab no. Recall kelas yes sebesar 33,74 persen menunjukkan bahwa sebagian besar nasabah yang berlangganan belum terdeteksi. Pada tugas seperti ini, presisi, recall, dan F1-score perlu dilaporkan bersama akurasi agar gambaran performa model lengkap.
8. **Keterbatasan.** Fitur duration hanya diketahui setelah panggilan selesai, sehingga pada penerapan nyata fitur ini tidak tersedia ketika prediksi dibuat. Akurasi yang terlihat pada praktikum ini kemungkinan lebih tinggi dibanding kondisi nyata. Teknik penanganan ketidakseimbangan kelas belum diterapkan pada kode final dan dapat menjadi langkah lanjutan.

Jawaban untuk rumusan masalah pertama adalah bahwa regresi linear sederhana dan berganda belum mampu memprediksi saldo nasabah dengan baik. Usia hanya menjelaskan 0,61 persen variasi saldo, dan penambahan seluruh fitur hanya menaikkan R2 menjadi 3,57 persen. Kedua model memiliki RMSE yang mendekati simpangan baku balance, sehingga keduanya belum memberi perbaikan berarti dibanding menebak nilai rata-rata.

Jawaban untuk rumusan masalah kedua adalah bahwa decision tree cukup baik untuk memprediksi keputusan berlangganan, dengan akurasi uji 0,9009. Namun, kemampuan model dalam mengenali nasabah yang berlangganan masih terbatas, ditunjukkan oleh recall kelas yes sebesar 0,3374. Jawaban ini perlu dibaca bersama metrik lain, bukan hanya akurasi.

Jawaban untuk rumusan masalah ketiga adalah max_depth 6 dipilih karena memberikan akurasi validasi tertinggi, yaitu 0,9013. Pada kedalaman yang lebih besar, akurasi latih terus naik, tetapi akurasi validasi tidak ikut naik. Pola ini menunjukkan bahwa pembatasan kedalaman efektif dalam mengurangi overfitting.

Jawaban untuk rumusan masalah keempat adalah bahwa kondisi data memengaruhi hasil secara nyata. Nilai unknown yang besar pada poutcome dan contact, outlier pada balance, serta ketidakseimbangan kelas target ikut membatasi hasil model. Kondisi-kondisi ini perlu dicatat agar kesimpulan yang diambil tidak melebihi kemampuan data.

DAFTAR PUSTAKA

Abidin, D. Z., Rosario, M., Sadikin, A., Nurhadi, & Jasmir. (2025). Improving term deposit customer prediction using support vector machine with SMOTE and hyperparameter tuning in bank marketing campaigns. *Jurnal Teknik Informatika (JUTIF)*, *6*(3), 1267-1278. https://doi.org/10.52436/1.jutif.2025.6.3.4585

Alsulami, A., Khalifa, R., & Alghamdi, W. (2026). Improving performance and accuracy in decision trees: A literature survey on impurity functions. *International Journal of Advanced Computer Science and Applications*, *17*(4), 985-1000. https://thesai.org/Downloads/Volume17No4/Paper_95-Improving_Performance_and_Accuracy_in_Decision_Trees.pdf

Antoska-Knights, V., & Prchkovska, M. (2024). From equations to predictions: Understanding the mathematics and machine learning of multiple linear regression. *Journal of Mathematical & Computer Applications*, *3*(2), 1-8. https://eprints.uklo.edu.mk/id/eprint/9901/

Chaudhry, M., Shafi, I., Mahnoor, M., Ramírez Vargas, D. L., Thompson, E. B., & Ashraf, I. (2023). A systematic literature review on identifying patterns using unsupervised clustering algorithms: A data mining perspective. *Symmetry*, *15*(9), 1679. https://doi.org/10.3390/sym15091679

Drăgoi, M.-V., Afram, R. M., Alzubaidi, A. A. A. M. H., Jiga, G. G., Ali, H. A., Puiu, R.-A., Petrea, G., & Hank, A. (2026). Comparative analysis of interpolation and extrapolation methods in regression models. *U.P.B. Scientific Bulletin, Series C*, *88*(1), 146-160. https://www.scientificbulletin.upb.ro/static/pdfs/C_11_16518_Roxana%20Puiu_pag.pdf

Ele, B. C., & Ideochi, O. (2023). Correlation analysis: A valuable tool in medical research. *Journal of Health, Applied Sciences and Management*, *7*(1), 91-100. https://doi.org/10.4314/johasam.v7i1.10

Halabaku, E., & Bytyçi, E. (2024). Overfitting in machine learning: A comparative analysis of decision trees and random forests. *Intelligent Automation & Soft Computing*, *39*(6). https://doi.org/10.32604/iasc.2024.059429

Halimatussa'diyah, U., & Rohman, A. (2026). Prediksi prestasi siswa menggunakan algoritma decision tree C4.5. *Jurnal Algoritma*, *23*(1), 51-58. https://doi.org/10.33364/algoritma/v.23-1.3111

Harefa, K. (2025). Application of multiple linear regression algorithm for house price estimation based on building location and area to improve predictive accuracy in real estate valuation. *RJTI Riau Jurnal Teknik Informatika*, *4*(3), 436-440. https://doi.org/10.52158/rjti.v4i3.3993

Hasnataeni, Y., Sadik, K., Soleh, A. M., & Astari, R. A. (2025). Comparison of ensemble learning methods in classifying unbalanced data on the bank marketing dataset. *Inferensi*, *8*(1), 35-43. https://doi.org/10.12962/j27213862.v8i1.20569

Hayder, I. M., Al Ali, G. A. N., & Younis, H. A. (2023). Predicting reaction based on customer's transaction using machine learning approaches. *International Journal of Electrical and Computer Engineering (IJECE)*, *13*(1), 1086-1096. https://doi.org/10.11591/ijece.v13i1.pp1086-1096

Pradana, M. A., Putra, R. S., Misbachuddin, M., & Puspaningrum, E. Y. (2024). Penerapan algoritma C4.5 untuk klasifikasi penyakit jantung. *Jurnal Informatika dan Sistem Informasi (JIFoSI)*, *5*(3). https://doi.org/10.33005/jifosi.v5i3.471

Rambe, K. B., Harahap, N. F., & Amir, A. (2025). Pemanfaatan regresi linier sederhana dalam penelitian pendidikan dasar: Kajian literatur sistematis. *Pendas: Jurnal Ilmiah Pendidikan Dasar*, *10*(4), 244-257. https://journal.unpas.ac.id/index.php/pendas/article/download/39845/20949/143968

Surahmat, A., & Sutrisno, M. (2023). Analisis kepuasan pelanggan dalam industri teknologi menggunakan algoritma C4.5. *Just IT: Jurnal Sistem Informasi, Teknologi Informasi dan Komputer*, *13*(2), 75-79. https://jurnal.umj.ac.id/index.php/just-it/article/download/18155/9086

Syakrani, N., & Athaya S. R., N. (2025). Konsistensi model regresi empat variabel pada populasi dan sampel untuk prediksi temperatur. *Journal of Applied Computer Science and Technology (JACOST)*, *6*(1), 9-16. https://doi.org/10.52158/jacost.v6i1.971